

Introduction aux LLMs

Séance 1 — Du texte brut aux Transformers

4ème année RO DEV — ESGI Paris

Célia Nouri · `celia.nouri@inria.fr`

Semestre 2, 2025–2026

Plan de la séance

~2h de cours + lab Python (3h total)

Au programme aujourd'hui

1. Pourquoi le langage est difficile ?
2. Les bases du NLP classique
3. Rappel Machine Learning & rétropropagation
4. Représenter les mots : de Bag-of-Words à Word2Vec
5. L'architecture Transformer
6. Pré-entraînement & Fine-tuning

Objectif : construire une intuition solide sur le NLP pour comprendre les LLMs dans les séances suivantes

À propos de ce cours

Volume	15h — 5 séances de 3h
Format	~1h30 cours + ~1h30 lab Python
Éval	QCM 40 questions (31 juillet)
Prérequis	Python, bases ML, APIs REST

✉ Questions & bugs : `celia.nouri@inria.fr`

1. Pourquoi le langage est difficile ?

Le langage est ambigu par nature

Le sens d'un mot dépend de son **contexte**.

"Je vois un homme avec un télescope."

Qui a le télescope ? Moi ou l'homme ?

"La banque est en face."

Banque financière, ou rive d'un fleuve ?

"C'est pas mal."

En français familier → c'est souvent **bien** !

Le langage n'est **pas un système formel**. C'est ce qui rend le NLP difficile — et fascinant.

Ce que les LLMs ont appris à modéliser

Pour désambiguïser, il faut comprendre le **contexte**.

"La **banque** accordera un prêt" → banque financière

"La **banque** est couverte de roseaux" → rive fluviale

Les LLMs modernes produisent des **représentations différentes** pour le même mot selon son contexte. C'est la grande avancée par rapport aux méthodes classiques.



Discussion : Donnez un exemple de mot/phrased français·e dont le sens change selon le contexte.

2. Les bases du NLP classique

Qu'est-ce qu'un token ?

Un **token** = l'unité de base que le modèle traite. Ce n'est **pas forcément un mot**.

"J'adore l'intelligence artificielle !"

Découpage	Résultat
Par mot	[J', adore, l', intelligence, artificielle, !]
Par sous-mot (BPE)	[J', ador, ##e, l', intel, ##ligence, ...]
Par caractère	[J, ', a, d, o, r, e, ...]

Les LLMs modernes utilisent le **sous-mot** (BPE, SentencePiece). Vocabulaires de 50k–100k tokens.

Pourquoi des sous-mots ?

Par caractère ✗ — séquences très longues, pas de sémantique portée

Par mot entier ✗ — mots rares, nouvelles entités, formes fléchies (`courons` , `courais` ...)

Par sous-mot ✓ — bon compromis : vocabulaire fini, mots inconnus décomposables

```
"ChatGPT" → ["Chat", "G", "PT"]    # mot inconnu → décomposé  
"courons" → ["cour", "ons"]        # morphologie préservée
```

On verra BPE en détail en **séance 2**.

Stemming vs Lemmatisation

Deux techniques pour **normaliser** les formes d'un mot.

Stemming — couper la fin, rapide mais approximatif

```
"courais", "courons", "courir" → "cour" ← pas un vrai mot !
```

Lemmatisation — forme canonique, tient compte du contexte grammatical

```
"courais", "courons", "courir" → "courir"  
"meilleures", "meilleur" → "bon" ← le lemme de "meilleur" !
```

Librairie recommandée : **spaCy** (Python)

Stop words & Regex

Stop words : mots si fréquents qu'ils ne portent pas de sens discriminant.

```
# Exemple avec spaCy
[token for token in doc if not token.is_stop]
# "le", "de", "et", "un"... → retirés
```

⚠ Attention au contexte : "*Être ou **ne pas** être*" — les stop words comptent ici !

Expressions régulières : patterns pour extraire des structures dans le texte.

```
import re
re.findall(r'\d{2}-\d{2}-\d{2}-\d{2}-\d{2}', texte) # → numéros de téléphone
re.findall(r'[\w.-]+@[ \w.-]+\.\w+', texte)         # → emails
```

La loi de Zipf

Dans **toute** langue humaine : le mot le plus fréquent apparaît $\sim 2\times$ plus que le 2e, $\sim 3\times$ plus que le 3e...

```
Rang 1  : "le"    → ~7% de tous les tokens  
Rang 2  : "de"    → ~3.5%  
Rang 10 : "un"    → ~0.7%  
Rang 100: ...     → très rare
```

Conséquence pratique :

- ~ 100 mots couvrent $\sim 50\%$ de tout texte
- La grande majorité du vocabulaire est **très rare**
- Les modèles doivent gérer des données très déséquilibrées

Quiz 1

Le lemme du mot **"allées"** (dans *"les allées du parc"*) est :

- A) "allé"
- B) "aller"
- C) "allée"
- D) "alle"

→ Réponse dans 30 secondes

🧩 Quiz 1 — Réponse

Réponse : C — "allée"

"Allées" est ici un **nom commun** (*les allées du parc*).

Le lemme d'un nom commun est son singulier : allée .

Si c'était le **participe passé** du verbe *aller* ("*elles sont allées*"),
le lemme serait aller .

Le contexte grammatical change le lemme — c'est pourquoi la lemmatisation demande une analyse syntaxique, pas juste une règle de troncature.

3. Rappel Machine Learning

C'est quoi, apprendre ?

Un modèle ML = une **fonction paramétrique**.

$$\hat{y} = f(x; \theta)$$

- x = entrée (texte, image...)
- $\hat{y}$ = prédiction du modèle
- θ = **paramètres** (poids) — des millions voire milliards de nombres

Apprendre = trouver les θ qui minimisent l'écart entre $\hat{y}$ et la vraie réponse y .

La fonction de perte (Loss)

On mesure l'erreur du modèle avec une **fonction de perte** $\mathcal{L}$.

Pour une classification binaire (ex. spam / pas spam) :

$$\mathcal{L} = - \left[y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y}) \right]$$

C'est la **cross-entropy**. Plus $\mathcal{L}$ est faible, mieux le modèle prédit.

Objectif : trouver θ^* tel que $\mathcal{L}$ soit minimale sur les données d'entraînement.

Descente de gradient

Idée : se déplacer dans la direction qui **réduit** la perte.

$$\theta \leftarrow \theta - \alpha \cdot \frac{\partial \mathcal{L}}{\partial \theta}$$

- α = **learning rate** (taux d'apprentissage) — hyperparamètre crucial
- $\frac{\partial \mathcal{L}}{\partial \theta}$ = gradient = direction de la pente ascendante

Analogie : vous êtes dans le brouillard sur une montagne. Vous voulez descendre dans la vallée. À chaque pas, vous regardez la pente sous vos pieds et avancez dans la direction la plus raide vers le **bas**.

Rétropropagation (Backpropagation)

Dans un réseau de neurones, le gradient se calcule par **rétropropagation** :

Forward pass :

$x \rightarrow [\text{Couche 1}] \rightarrow [\text{Couche 2}] \rightarrow [\text{Couche 3}] \rightarrow \hat{y} \rightarrow L$

Backward pass (règle de la chaîne) :

$\partial L / \partial \theta_1 \leftarrow \partial L / \partial \theta_2 \leftarrow \partial L / \partial \theta_3 \leftarrow \partial L / \partial \hat{y}$

La **règle de la chaîne** permet de calculer les gradients couche par couche, de la sortie vers l'entrée.

PyTorch / TensorFlow font ça automatiquement (**autograd**).

Surapprentissage (Overfitting)

Le modèle **mémore** les données d'entraînement au lieu d'en apprendre les patterns.

	Train accuracy	Test accuracy
✓ Bon modèle	92%	89%
✗ Overfitting	99%	62%

Solutions courantes :

- **Dropout** : désactiver des neurones aléatoirement pendant l'entraînement
- **Weight decay** : pénaliser les poids trop grands (L_2 régularisation)
- **Early stopping** : arrêter quand la validation stagne
- **Plus de données** : le remède le plus efficace

Quiz 2

Un modèle atteint **99% d'accuracy** sur les données d'entraînement et **62%** sur les données de test.

Que se passe-t-il ?

- **A)** Le modèle est parfait, 99% c'est excellent
- **B)** Il y a du surapprentissage (*overfitting*)
- **C)** Les données de test sont mauvaises
- **D)** Le learning rate est trop élevé

4. Représenter les mots en vecteurs

Le problème central

Les modèles mathématiques ne comprennent que des **chiffres**.
Il faut **encoder** le texte sous forme de vecteurs numériques.

Trois générations de méthodes :

	Méthode	Sémantique
1	One - Hot / BoW / TF - IDF	✗ aucune
2	Word2Vec, GloVe, FastText	✓ statique
3	BERT, GPT (Transformers)	✓✓ contextuelle

One-Hot Encoding

Chaque mot = un vecteur avec un 1 à sa position dans le vocabulaire.

```
Vocabulaire : [chat, chien, maison, voiture, soleil]
```

```
chat    = [1, 0, 0, 0, 0]
```

```
chien   = [0, 1, 0, 0, 0]
```

```
maison  = [0, 0, 1, 0, 0]
```

Problèmes :

- Vecteurs immenses (taille du vocabulaire $\geq 50\,000$)
- Aucune relation entre mots : `chat` et `chien` sont aussi différents que `chat` et `voiture`
- Très creux (*sparse*) → inefficace en mémoire

Bag of Words (BoW)

Pour une phrase : compter les occurrences de chaque mot du vocabulaire.

Phrase : *"Le chat mange le poisson"*

Vocabulaire : [chat, chien, mange, poisson, maison, le]

```
BoW = [1, 0, 1, 1, 0, 2]
```

✅ Simple, fonctionne pour la classification de documents

❌ L'ordre des mots est perdu :

"Le chat mange le poisson" = *"Le poisson mange le chat"* 🤪

TF-IDF

Amélioration de BoW : pondérer les mots par leur **rareté** dans le corpus.

$$\text{TF-IDF}(t, d) = \underbrace{\text{TF}(t, d)}_{\text{fré q. dans le doc}} \times \underbrace{\log\left(\frac{N}{\text{df}(t)}\right)}_{\text{rareté globale}}$$

- **TF** : fréquence du terme t dans le document d
- **df** : nombre de documents contenant t
- **N** : nombre total de documents

"le", "de" apparaissent partout → IDF faible → peu d'importance

"transformer", "tokenisation" → IDF élevé → très informatifs

Word2Vec — Le tournant (2013)

Mikolov et al., Google, 2013 — probablement le papier NLP le plus influent avant les Transformers.

Idée clé (Firth, 1957) :

"A word is known by the company it keeps."

Le sens d'un mot peut être inféré des mots qui l'**entourent**.

Word2Vec entraîne un petit réseau sur une tâche simple :

- **Skip-gram** : étant donné un mot central, prédire les mots du contexte
- **CBOW** : étant donné le contexte, prédire le mot central

Word2Vec — Comment ça marche

Skip-gram sur la phrase *"Le [chat] dort sur le tapis"* :

```
Mot central : "chat"  
    ↓  
Prédire : "Le", "dort", "sur", "le"
```

Le réseau apprend des **vecteurs denses** (100–300 dimensions) pour chaque mot.

La magie : deux mots qui apparaissent dans des **contextes similaires** auront des vecteurs proches.

Word2Vec — Résultats célèbres

```
vecteur("roi") - vecteur("homme") + vecteur("femme")  
≈ vecteur("reine")
```

Les directions dans l'espace vectoriel ont un **sens** :

- Direction **genre** : roi → reine, acteur → actrice
- Direction **capitale** : France → Paris, Allemagne → Berlin
- Direction **pluriel** : chat → chats, chien → chiens

Ce n'est pas de la magie — c'est une conséquence statistique de l'entraînement sur des milliards de phrases.

🧩 Quiz 3 — En binôme (2 min)

Avec des embeddings Word2Vec bien entraînés, que devrait-on obtenir pour :

$$\text{vecteur("Paris")} - \text{vecteur("France")} + \text{vecteur("Allemagne")} \approx ?$$

Discutez avec votre voisin·e. Réponse dans 2 minutes.

🧩 Quiz 3 — Réponse

Réponse : "Berlin"

La relation **capitale** ↔ **pays** est encodée comme une direction dans l'espace vectoriel.

```
Paris - France = vecteur("est la capitale de")  
Berlin - Allemagne = vecteur("est la capitale de")
```

Limite critique de Word2Vec : les embeddings sont **statiques** — un seul vecteur par mot.
Le mot "*banque*" a le **même vecteur** qu'il s'agisse d'une banque financière ou d'une rive.
→ C'est ce que BERT & GPT vont résoudre.

Autres embeddings statiques

Modèle	Auteurs	Particularité
Word2Vec	Mikolov et al. (2013)	Skip-gram / CBOW
GloVe	Pennington et al. (2014)	Co-occurrences globales
FastText	Joulin et al. (2016)	Sous-mots → gère mots rares

FastText est particulièrement robuste sur les **langues morphologiquement riches** (allemand, finnois, arabe...) et les mots hors-vocabulaire.

5. Les RNNs

Une étape intermédiaire nécessaire

Réseaux Récurrents (RNNs)

Avant les Transformers (2017), les RNNs dominaient le NLP.

Principe : traiter les tokens **un par un**, en maintenant un **état caché** h_t .

```
x1 → [RNN] → h1  
x2 → [RNN] → h2    (h1 alimente h2)  
x3 → [RNN] → h3    (h2 alimente h3)  
⋮
```

Intuitif : on lit la phrase mot à mot, la compréhension s'accumule.

Le problème du gradient qui disparaît

Sur de longues séquences, les gradients se multiplient à chaque pas.

$$\frac{\partial \mathcal{L}}{\partial h_1} = \frac{\partial \mathcal{L}}{\partial h_T} \cdot \prod_{t=2}^T \frac{\partial h_t}{\partial h_{t-1}}$$

Si chaque terme $< 1 \rightarrow$ le gradient devient exponentiellement **petit**.

Les premiers tokens n'apprennent plus rien.

Solutions partielles :

- **LSTM** (Hochreiter & Schmidhuber, 1997) — portes de mémoire
- **GRU** (Cho et al., 2014) — version simplifiée du LSTM
- Limitation persistante : traitement **séquentiel**, pas de parallélisation

6. Le Transformer

"Attention is All You Need"

Vaswani et al., 2017

L'idée radicale

Se débarrasser de la récurrence.

Au lieu de traiter les tokens un par un, permettre à **chaque token de regarder directement tous les autres** en même temps.

Avantages immédiats :

-  **Parallélisation** totale → entraînement massivement accéléré sur GPU
-  **Dépendances longue distance** capturées sans dégradation
-  **Scalabilité** : plus de paramètres = meilleur modèle (jusqu'à un certain point)

Le mécanisme d'Attention

Intuition : pour comprendre "il" dans "Le chat s'est couché. Il ronronne.", le modèle doit faire attention à "chat" quelques tokens plus tôt.

Chaque token produit **3 vecteurs** :

Vecteur	Rôle
Query (Q)	"Qu'est-ce que je cherche ?"
Key (K)	"Qu'est-ce que je représente ?"
Value (V)	"Quelle information j'apporte ?"

Attention — Le calcul

Score d'attention entre le token i et le token j :

$$\text{score}(i, j) = \text{softmax}\left(\frac{Q_i \cdot K_j}{\sqrt{d_k}}\right)$$

Sortie pour le token i = somme pondérée des valeurs :

$$\text{output}_i = \sum_j \text{score}(i, j) \cdot V_j$$

La division par $\sqrt{d_k}$ évite que les produits scalaires deviennent trop grands et saturent le softmax.

Attention — Pourquoi ça marche

Tous ces calculs se font **en parallèle** via des multiplications matricielles.

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) \cdot V$$

Ce que le modèle apprend : quels tokens sont pertinents pour chaque position.

Sur la phrase *"La banque a refusé le prêt car elle manquait de fonds"* :

- Pour résoudre *"elle"* → forte attention sur *"banque"*
- Pour résoudre *"fonds"* → forte attention sur *"prêt"* et *"manquait"*

Multi-Head Attention

Plutôt qu'une seule attention, le Transformer en utilise **plusieurs en parallèle**.

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \cdot W^O$$

Chaque tête peut se **spécialiser** :

- Tête 1 → relations syntaxiques (sujet-verbe)
- Tête 2 → relations sémantiques (synonymes)
- Tête 3 → coréférences (pronom → antécédent)
- ...

GPT-3 : 96 têtes d'attention par couche.

Encodage positionnel

Problème : l'attention est indépendante de l'ordre des tokens !

"Le chat mange le poisson" = "Le poisson mange le chat" sans correction.


Solution : ajouter un **encodage positionnel** à chaque embedding.

$$\text{embedding_final} = \text{embedding_mot} + \text{encodage_position}$$

Dans le papier original : fonctions sinus/cosinus à différentes fréquences.

Les modèles modernes apprennent souvent ces positions directement (RoPE, ALiBi...).

Architecture complète



- **Encodeur** → comprendre la séquence source (BERT)
- **Décodeur** → générer la séquence cible (GPT, Claude)
- **Encodeur+Décodeur** → traduction, résumé (T5, BART)

Les deux familles

	Encodeur seul	Décodeur seul
Exemple	BERT (2018, Google)	GPT- 1/2/3/4 (OpenAI)
Attention	Bidirectionnelle	Causale (gauche → droite)
Objectif	Comprendre / classifier	Générer du texte
Tâches	Classification, NER, QA	Génération, dialogue

Les LLMs actuels — **GPT-4, Claude, Llama, Mistral** — sont presque tous des **décodeurs**.

Quiz 4

Pourquoi les Transformers s'entraînent-ils **plus vite** que les RNNs sur GPU ?


- A) Ils ont moins de paramètres
- B) L'attention calcule toutes les relations en parallèle via opérations matricielles
- C) Ils n'utilisent pas de rétropropagation
- D) Ils traitent les tokens par blocs de 10

7. Pré-entraînement & Fine-tuning

La logique des LLMs modernes

Étape 1 — Pré-entraînement : tâche non supervisée, immense corpus

Étape 2 — Fine-tuning : adaptation à une tâche spécifique



Pourquoi cette séparation ? Le pré-entraînement est coûteux mais ne se fait qu'une fois. Le fine-tuning est rapide et cheap.

Pré-entraînement : prédire le prochain token

Pour un modèle décodeur (type GPT), la tâche est :

Étant donné tous les tokens précédents, prédire le suivant.

```
Input  : "Le chat est assis sur le"  
Cible  : "tapis"
```

- Aucune annotation humaine nécessaire — tout texte est une donnée gratuite
- GPT-3 : ~300 milliards de tokens d'entraînement
- LLaMA 3 : ~15 000 milliards de tokens

Ce que le modèle apprend implicitement

En apprenant à prédire la suite, le modèle doit **modéliser** :

- La **grammaire** (pour prédire la bonne forme)
- Les **faits du monde** (Paris est la capitale de la France)
- Le **raisonnement** (si A alors B)
- Le **style** et le **ton**
- Les **relations entre concepts**

"Les LLMs ne savent pas ce qu'ils savent. Ils savent ce qui est probable."

Fine-tuning

Une fois pré-entraîné, on **spécialise** le modèle.

Type	Exemple
SFT (Supervised FT)	Paires (instruction, réponse souhaitée)
Domain FT	Textes médicaux, juridiques, financiers
RLHF	Feedback humain → préférences → alignement

On verra SFT, RLHF et DPO en **séance 2**.

Récapitulatif

```
Texte brut
  ↓ tokenisation
Séquence de tokens
  ↓ embeddings
Vecteurs denses
  ↓ Transformer (attention)
Représentations contextuelles
  ↓ tête de prédiction
Distribution sur le vocabulaire
  ↓ sampling / argmax
Prochain token généré
```

Ce que vous devez retenir

- **Token** $\neq$ mot. Les LLMs opèrent sur des sous-mots.
- **Lemmatisation** $\rightarrow$ forme canonique, tient compte du contexte grammatical
- **Word2Vec** $\rightarrow$ embeddings statiques, capturent la sémantique par le contexte
- **Attention** $\rightarrow$ chaque token peut regarder tous les autres en parallèle
- **Transformer** $\rightarrow$ parallélisation + dépendances longue distance
- **Pré-entraînement** $\rightarrow$ apprendre le langage sur des milliards de tokens
- **Fine-tuning** $\rightarrow$ spécialiser pour une tâche

🧩 Quiz final — 5 minutes

1. Quelle est la différence entre un token et un mot ?
2. Dans l'attention, à quoi servent Q, K et V ?
 - A) Question, Clé de tri, Valeur d'apprentissage
 - B) Requête, Clé de correspondance, Contenu à agréger ✓
 - C) Ils sont interchangeables
3. Vrai/Faux : Word2Vec résout l'ambiguïté du mot "*banque*".
4. Pourquoi entraîner sur la prédiction du prochain token est-il une bonne façon d'apprendre le langage ?

Ressources clés

- 📄 **Word2Vec** — Mikolov et al. (2013) — arxiv.org/abs/1301.3781
- 📄 **Attention is All You Need** — Vaswani et al. (2017) — arxiv.org/abs/1706.03762
- 📄 **GloVe** — Pennington et al. (2014) — nlp.stanford.edu/projects/glove
- 📄 **LSTM** — Hochreiter & Schmidhuber (1997) — Neural Computation

- 🔧 **spaCy** — spacy.io | **Hugging Face** — huggingface.co
- 📖 **CS224n** (Stanford NLP) — cours en ligne gratuit, excellent

Avant la séance 2 : lire l'abstract de *"Attention is All You Need"*.

Lab — Aujourd'hui (1h30)

Partie 1 — Pré-traitement avec `spaCy`

Tokeniser, lemmatiser, retirer les stop words sur un jeu de textes.

Partie 2 — Embeddings BoW & TF-IDF avec `scikit-learn`

Visualiser les vecteurs (PCA), comparer des documents.

Partie 3 — Word2Vec avec `gensim`

Explorer les analogies et les voisins sémantiques.

Partie 4 — Premier contact avec les Transformers

Charger un modèle Hugging Face, obtenir des embeddings contextuels.

Séance 2 — 12 juin

Entraînement : comment construit-on un LLM ?

Pré-entraînement à grande échelle · Lois de Chinchilla

Instruction tuning & RLHF · Évaluation

Lectures conseillées :

Vaswani et al. (2017), "Attention is All You Need" — abstract + intro

`celia.nouri@inria.fr`