

# Introduction aux LLMs

Séance 1 — Du NLP symbolique aux Transformers

---

4ème année RO DEV - ESGI Paris

Célia Nouri · `celia.nouri@inria.fr`

Semestre 2, 2025–2026

# Plan de la séance

---

~2h de cours + lab Python (4h total)

## Au programme aujourd'hui

1. Introduction
2. Les bases du traitement automatique du langage
3. Rappels : Machine Learning & rétropropagation
4. Représentations vectorielles des mots : de Bag-of-Words à Word2Vec
5. L'architecture Transformer

**Objectif** : construire une intuition solide sur le TAL (NLP) pour comprendre les LLMs dans les séances suivantes

## À propos de ce cours

| <b>Volume</b>    | 20h — 5 séances de 4h         |
|------------------|-------------------------------|
| <b>Format</b>    | ~2h cours + ~2h lab Python    |
| <b>Éval</b>      | QCM 40 questions (31 juillet) |
| <b>Prérequis</b> | Python, bases ML, APIs REST   |

✉ Questions & bugs : `celia.nouri@inria.fr`



# 1. Introduction

---

## Qu'est-ce que le TAL ?

Traitement automatique du langage (naturel, distinction avec le langage informatique ou code).

**Discussion** : Qu'est-ce que le TAL ?

## Le langage est ambigu par nature

Le sens n'est pas uniquement contenu dans les mots eux-mêmes : il dépend de la syntaxe, du contexte discursif, de la situation d'énonciation, des connaissances du monde et des intentions du locuteur...

### Ambiguïté lexicale

*"Donne-moi la batterie."*

L'instrument de musique ? La pile électrique ?

### Ambiguïté syntaxique

*"J'ai vu l'homme avec les jumelles."*

Qui a les jumelles ? Moi ou l'homme.

## Connaissance du monde

- "Marc s'est assis, a regardé le menu."  
Sous-entendu : Marc est au restaurant.

## Connaissances culturelles

"C'est pas mal."\*

En français familier, c'est **bien** !

## Ironie / Sarcasme

Après 2h de retard : "Super, t'es vraiment ponctuel."


Sens réel : critique / sens littéral: compliment.

## Dépendance au contexte pragmatique

"Tu peux ouvrir la fenêtre ?"

Sens réel : demande d'ouvrir. Sens littéral : capacité d'ouvrir.

# Le langage est ambigu par nature



## Ce que les LLMs ont appris à modéliser

Pour désambiguïser, il faut comprendre le **contexte**.

"La **batterie** est déchargée" → batterie électrique

"La **batterie** est facile à apprendre" → l'instrument de musique


Les LLMs modernes produisent des **représentations différentes** pour le même mot selon son contexte. C'est la grande avancée par rapport aux représentations décontextualisées (pré-transformers). Mais cela ne suffit pas toujours à capturer les subtilités sociales, culturelles, conversationnelles du langage.

**Discussion** : Donnez des exemples de mot/phrased français·e dont le sens change selon le contexte.



## Où trouver des données textuelles ?

**Discussion** : Quelles sont les sources de données utilisées par le TAL.




## Les sources de données en TAL





Historique des avancées en TAL



### How to write a course for advanced NLP?




Writing a course for **advanced NLP (Natural Language Processing)** involves a thoughtful balance of theory, practical applications, and emerging trends in the field. You will need to structure the course to cover both foundational knowledge and the latest advancements in NLP. Below is a guide to help you develop a comprehensive and effective course.

### Step 1: Define Course Objectives

Start by identifying the key objectives for the course. For example, students should be able to:

# Le TAL en 2025-2026



## Le TAL en 2025-2026

*Génère une image de l'école d'informatique en alternance à Paris (ESGI) avec le logo de l'école et une bannière.*



# Le TAL en 2025-2026



×  

6 

TOUT RECHERCHER IMAGES VIDÉOS CARTES ACTUALITÉS COPILOT PLUS À PROPOS DES RÉSULTATS DE RECHERCHE

 Copilot Search   

D'accord 😊 Je vais te préparer un **cours clair et structuré sur le NLP (Traitement Automatique du Langage Naturel)**, adapté pour un apprentissage progressif.

On va le découper en **modules**, avec définitions, concepts clés, exemples et exercices.

### Cours de NLP – Introduction et Fondamentaux


#### Module 1 : Introduction au NLP

- **Définition** : Le NLP (Natural Language Processing) est un domaine de l'IA qui permet aux machines de comprendre, interpréter et générer du langage humain.
- **Applications courantes** :
  - Chatbots et assistants vocaux
  - Traduction automatique

↶ ↷ 📄 ↗ ✎ Adapter le contenu 🔄 Ré... Modifier la longueur ▾ Modifier la tonalité ▾ Essayer d'autres m... ▾


Techniques avancées de NLP Applications pratiques du NLP Outils open source NLP

# Le TAL en 22025-2026





## Le TAL en 2025-2026



# Est-ce que les tâches de TAL sont résolues ?

---

(NON.)



## Le TAL en 2025-2026

---



Give me a random string of length 35



Sure, here's a random string of length 35:



``J9kPzHfRq81G2sT7Nv6yX1W4c00mZoBwA5U3j``

>



Can you invert all letters in the following sentence: "I am currently giving an interesting course in Natural Language Processing at EPITA in Le-Kremlin-Bicêtre."



Certainly! Here's the sentence with all the letters inverted:



"I ma yltnerurc ygivni na gnitseretni esruoc ni lartuaN egaugnol gnicsessorP ta ATIPE ni ertnebiC-tciB-nimeIK-eL."

## Le TAL en 2025-2026



It takes 3 hours to dry 3 towels. How long does it take to dry 9 towels?



If it takes 3 hours to dry 3 towels, it implies that you can dry 1 towel in 3 hours. To find out how long it takes to dry 9 towels, you can use the same rate:   

1 towel takes 3 hours to dry, so:

9 towels will take 9 times as long, which is:

9 towels x 3 hours/towel = 27 hours.

So, it will take 27 hours to dry 9 towels.

## Le TAL en 2025-2026



Let's picture the CEO of a very big international company. The CEO has to do a lot of business trips all around the world, so the CEO's wife is alone to help the children with the homework. Write the informal text message of the wife where she expresses her anger.



Sure, here's an informal text message where the CEO's wife expresses her frustration:

"Ugh, this is getting ridiculous! 🤯 Another week alone with the kids while he's jet-setting around the world. 🌍 Can't believe he's missing out on their lives. Homework's a mess, and I'm doing it all. 😡 When is he ever gonna slow down and be here for us?? 😭💔"



Write the next text message, where she positively describes the CEO physically in details (skin, eyes, hair, ...).



"Despite all the frustration, I can't deny that man's got a magnetic charm that's hard to resist. 😍 His skin is that perfect sun-kissed bronze, and those deep, piercing blue eyes always get me. ✨ His hair, just the right shade of salt and pepper, makes him look even more distinguished. 😍 Sometimes, it's just hard to stay mad at someone who looks like a movie star. 🌟"

## Organisation des séances



Célia Nouri  
celia.nouri@inria.fr

## Organisation des séances

- Objectives
  - **Connaissances** : comprendre l'architecture et le processus d'entraînement d'un LLM moderne, et les avancées récentes dans le domaine du TAL.
  - **Mise en practice** : Concevoir un système intégrant des LLMs modernes (RAG : Retrieval-Augmented Generation, agents) fonctionnel
  - **Distance Critique** : Comprendre les limites et problèmes actuels liés aux LLMs, et analyser les méthodes et avancées en maintenant une distance critique.

## Organisation des séances

- **Séance 1 (Aujourd'hui):** Fondations : Introduction, Recap ML, embeddings, Transformers
- **Séance 2 (12 juin):** Entraînement : Tokenization, Pré-entraînement, Fine-tuning, Alignement
- **Séance 3 (10 juillet):** Utilisation et LLM-augmentés : Prompting, RAG
- **Séance 4 (24 juillet):** Agents : Toolformer, Architectures agentiques,
- **Séance 5 (28 juillet):** Frontière : Modèles de raisonnement, Multimodalité,
- **Examen (31 juillet):** QCM final 40 questions

## **2. Les bases du traitement automatique du langage**

---

# Qu'est-ce qu'un token ?

Un **token** = l'unité de base que le modèle traite. Ce n'est **pas forcément un mot**.

B

| Découpage          | Résultat                      |
|--------------------|-------------------------------|
| Par mot            | [J', adore, ce, cours, !]     |
| Par sous-mot (BPE) | [J', ador, ##e, ce, cours, !] |
| Par caractère      | [J, ', a, d, o, r, e, ...]    |

Les LLMs modernes utilisent le **sous-mot** (WordPiece, SentencePiece, BPE). Vocabulaires de 30k–100k tokens.



## Pourquoi des sous-mots ?

**Par caractère** — séquences très longues, pas de sémantique

**Par mot entier** — mots rares, néologismes, formes fléchies ( `courons` , `courais` ...)

**Par sous-mot** — bon compromis : vocabulaire fini, mots inconnus décomposables, formes fléchies rassemblées

```
"ChatGPT" → ["Chat", "G", "PT"]    # mot inconnu → décomposé  
"courons" → ["cour", "ons"]        # morphologie préservée
```

On verra les algorithmes de tokenization dont BPE en détail en **séance 2**.

## Stemming vs Lemmatisation

Deux techniques pour **normaliser** les formes d'un mot.

**Stemming** — couper la fin, rapide mais approximatif

```
"courais", "courons", "courir" → "cour" ← pas un vrai mot !
```

**Lemmatisation** — forme canonique, tient compte du contexte grammatical, mais coûteux

```
"courais", "courons", "courir" → "courir"  
"meilleures", "meilleur" → "bon" ← le lemme de "meilleur" !
```

Librairie recommandée : **spaCy** (Python)

## Stop words & Regex

**Stop words** : mots si fréquents qu'ils ne portent pas de sens discriminant.

```
# Exemple avec spaCy
[token for token in doc if not token.is_stop]
# "le", "de", "et", "un"... → retirés
```

⚠ Attention au contexte : "*Être ou **ne pas** être*" — les stop words comptent ici !

**Expressions régulières** : patterns pour extraire des structures dans le texte.

```
import re
re.findall(r'\d{2}-\d{2}-\d{2}-\d{2}-\d{2}', texte) # → numéros de téléphone
re.findall(r'[\w.-]+@[ \w.-]+\.\w+', texte)         # → emails
```

## La loi de Zipf


Dans **toute** langue humaine : le mot le plus fréquent apparaît  $\sim 2\times$  plus que le 2e,  $\sim 3\times$  plus que le 3e...

```
Rang 1  : "le"    → ~7% de tous les tokens  
Rang 2  : "de"    → ~3.5%  
Rang 10 : "un"    → ~0.7%  
Rang 100: ...     → très rare
```

### Conséquence pratique :

- $\sim 100$  mots couvrent  $\sim 50\%$  de tout texte
- La grande majorité du vocabulaire est **très rare**
- Les modèles doivent gérer des données très déséquilibrées

# La loi de Zipf



## Quiz 1

Le lemme du mot "allées" (dans "*les allées du parc*") est :

- A) "allé"
- B) "aller"
- C) "allée"
- D) "alle"

→ Réponse dans 30 secondes

## 🧩 Quiz 1 — Réponse

Réponse : C — "allée"

"Allées" est ici un **nom commun** (*les allées du parc*).

Le lemme d'un nom commun est son singulier : allée .

Si c'était le **participe passé** du verbe *aller* ("*elles sont allées*"),  
le lemme serait aller .

**Le contexte grammatical change le lemme** — c'est pourquoi la lemmatisation demande une analyse syntaxique, pas juste une règle de troncature.

### **3. Rappel Machine Learning**

---



## C'est quoi, l'apprentissage machine ?

Un modèle ML = une **fonction paramétrique**.

$$\hat{y} = f(x; \theta)$$

- $x$  = entrée (texte, image...)
- $\hat{y}$  = prédiction du modèle
- $\theta$  = **paramètres** (poids) — des millions voire milliards de variables à calibrer

**Apprendre** = trouver les  $\theta$  qui minimisent l'écart entre  $\hat{y}$  et la vraie réponse  $y$ .

## La fonction de perte (Loss)

On mesure l'erreur du modèle avec une **fonction de perte**  $\mathcal{L}$ .

Pour une classification binaire (ex. spam / pas spam) :

$$\mathcal{L} = - \left[ y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y}) \right]$$

C'est la **cross-entropy**. Plus  $\mathcal{L}$  est faible, mieux le modèle prédit.

**Objectif** : trouver  $\theta^*$  tel que  $\mathcal{L}$  soit minimale sur les données d'entraînement.

**Discussion** : comment trouver le minimum (s'il existe) de la fonction de perte ?

## Descente de gradient

L'objectif est de trouver le minimum de la fonction de perte, mais dans le cas des réseaux de neurones, cette fonction est la fonction est très complexe, non linéaire et multidimensionnelle.

Il impossible de résoudre ce problème directement avec la formule exacte "dérivée = 0".

Idée : se déplacer dans la direction qui **réduit** la fonction de perte.

$$\theta \leftarrow \theta - \alpha \cdot \frac{\partial \mathcal{L}}{\partial \theta}$$

- $\alpha$  = **learning rate** (taux d'apprentissage), un hyperparamètre crucial
- $\frac{\partial \mathcal{L}}{\partial \theta}$  = gradient = direction de la pente ascendante
- on se déplace à chaque étape de l'apprentissage en direction -  $\frac{\partial \mathcal{L}}{\partial \theta} x \alpha$

**Analogie** : vous êtes dans le brouillard sur une montagne. Vous voulez descendre dans la vallée. À chaque pas, vous regardez la pente sous vos pieds et avancez dans la direction la plus raide vers le **bas**.

## Rétropropagation (Backpropagation)

Dans un réseau de neurones, le gradient se calcule par **rétropropagation** :

Forward pass :

$x \rightarrow [\text{Couche 1}] \rightarrow [\text{Couche 2}] \rightarrow [\text{Couche 3}] \rightarrow \hat{y} \rightarrow L$

Backward pass (règle de la chaîne) :

$\partial L / \partial \theta_1 \leftarrow \partial L / \partial \theta_2 \leftarrow \partial L / \partial \theta_3 \leftarrow \partial L / \partial \hat{y}$

La **règle de la chaîne** permet de calculer les gradients couche par couche, de la sortie vers l'entrée.

PyTorch / TensorFlow font ça automatiquement (**autograd**).

## Surapprentissage (Overfitting)

Le modèle **mémore** les données d'entraînement au lieu d'en apprendre les patterns.

|             | Train accuracy | Test accuracy |
|-------------|----------------|---------------|
| Bon modèle  | 92%            | 89%           |
| Overfitting | 99%            | 62%           |

### Solutions courantes :

- **Dropout** : désactiver des neurones aléatoirement pendant l'entraînement
- **Weight decay** : pénaliser les poids trop grands ( $L_2$  régularisation)
- **Early stopping** : arrêter quand la validation stagne
- **Plus de données** : (et des données plus diverses et représentatives), le remède le plus efficace

## Quiz 2

Un modèle atteint **99% d'accuracy** sur les données d'entraînement et **62%** sur les données de test.

Que se passe-t-il ?

- **A)** Le modèle est parfait, 99% c'est excellent
- **B)** Il y a du surapprentissage (*overfitting*)
- **C)** Les données de test sont mauvaises
- **D)** Le learning rate est trop élevé

## 4. Représenter les mots en vecteurs

---

# Le problème central


Les modèles mathématiques ne comprennent que des **chiffres**.  
Il faut **encoder** le texte sous forme de vecteurs numériques.

Trois générations de méthodes :

|   | Méthode                    | Sémantique      |
|---|----------------------------|-----------------|
| 1 | One - Hot / BoW / TF - IDF | ✗ aucune        |
| 2 | Word2Vec, GloVe, FastText  | ✓ statique      |
| 3 | BERT, GPT (Transformers)   | ✓✓ contextuelle |



## Représentations vectorielles (embeddings)



## One-Hot Encoding

Chaque mot = un vecteur de la taille du vocabulaire avec un **1** à sa position dans le vocabulaire, et des **0** partout ailleurs.

```
Vocabulaire : [chat, chien, maison, voiture, soleil]
```

```
chat    = [1, 0, 0, 0, 0]
```

```
chien   = [0, 1, 0, 0, 0]
```

```
maison  = [0, 0, 1, 0, 0]
```

### Problèmes :

- Vecteurs immenses (taille du vocabulaire  $\geq 50\,000$ )
- Aucune relation entre mots : `chat` et `chien` sont aussi différents que `chat` et `voiture`
- Très creux (*sparse*) → inefficace en mémoire

## Bag of Words (BoW)

Pour une phrase : compter les occurrences de chaque mot du vocabulaire.

**Phrase :** *"Le chat mange le poisson"*

**Vocabulaire :** [chat, chien, mange, poisson, maison, le]

```
BoW = [1, 0, 1, 1, 0, 2]
```

✓ Simple, fonctionne pour la classification de documents

✗ L'ordre des mots est perdu :

*"Le chat mange le poisson" = "Le poisson mange le chat"*

## TF-IDF

Amélioration de BoW : pondérer les mots par leur **rareté** dans le corpus.

$$\text{TF-IDF}(t, d) = \underbrace{\text{TF}(t, d)}_{\text{fré q. dans le doc}} \times \underbrace{\log\left(\frac{N}{\text{df}(t)}\right)}_{\text{rareté globale}}$$

- **TF** : fréquence du terme  $t$  dans le document  $d$
- **df** : nombre de documents contenant  $t$
- **N** : nombre total de documents

"le", "de" apparaissent partout → IDF faible → peu d'importance

"transformer", "tokenisation" → IDF élevé → très informatifs

## TF-IDF

$$w_{x,y} = \text{tf}_{x,y} \times \log \left( \frac{N}{\text{df}_x} \right)$$

### TF-IDF

Term  $x$  within document  $y$

$\text{tf}_{x,y}$  = frequency of  $x$  in  $y$

$\text{df}_x$  = number of documents containing  $x$

$N$  = total number of documents

## Word2Vec — Le tournant (2013)

Mikolov et al., Google, 2013 (probablement le papier en TAL le plus influent avant les Transformers).

Idée clé (Firth, 1957) :

*"A word is known by the company it keeps."*


Le sens d'un mot peut être inféré en regardant les mots qui l'**entourent**.

Word2Vec entraîne un petit réseau sur une tâche simple :

- **Skip-gram** : étant donné un mot central, prédire les mots du contexte
- **CBOW** : étant donné le contexte, prédire le mot central

## Word2Vec — Comment ça marche

Apprend les représentations vectorielles des mots **sans supervision**.



## Word2Vec — Comment ça marche

Skip-gram sur la phrase *"Le [chat] dort sur le tapis"* :

```
Mot central : "chat"  
    ↓  
Prédire : "Le", "dort", "sur", "le"
```

Le réseau apprend des **vecteurs denses** (100–300 dimensions) pour chaque mot.

Cohérence sémantique : deux mots qui apparaissent dans des **contextes similaires** auront des vecteurs proches.



## Word2Vec — Résultats célèbres


```
vecteur("roi") - vecteur("homme") + vecteur("femme")  
≈ vecteur("reine")
```

Certaines directions dans l'espace vectoriel ont un **sens** :

- Direction **genre** : roi → reine, acteur → actrice
- Direction **capitale** : France → Paris, Allemagne → Berlin
- Direction **pluriel** : chat → chats, chien → chiens

Conséquence statistique de l'entraînement sur des milliards de phrases.

## Espace latent (vectoriel)



### Quiz 3

Avec des embeddings Word2Vec bien entraînés, que devrait-on obtenir pour :

$$\text{vecteur}(\text{"Paris"}) - \text{vecteur}(\text{"France"}) + \text{vecteur}(\text{"Allemagne"}) \approx ?$$

## 🧩 Quiz 3 — Réponse

Réponse : "Berlin"

La relation **capitale** ↔ **pays** est encodée comme une direction dans l'espace vectoriel.

```
Paris - France = vecteur("est la capitale de")  
Berlin - Allemagne = vecteur("est la capitale de")
```

**Limite critique de Word2Vec** : les embeddings sont **statiques** : un seul vecteur par mot.

Le mot "*batterie*" a le **même vecteur** qu'il s'agisse de l'instrument de musique ou de la pile électrique.

→ C'est ce que les Transformers vont résoudre.

# Autres embeddings statiques

| Modèle   | Auteurs                  | Particularité               |
|----------|--------------------------|-----------------------------|
| Word2Vec | Mikolov et al. (2013)    | Skip-gram / CBOW            |
| GloVe    | Pennington et al. (2014) | Co-occurrences globales     |
| FastText | Joulin et al. (2016)     | Sous-mots → gère mots rares |

FastText est particulièrement robuste sur les **langues morphologiquement riches** (allemand, finnois, arabe...) et les mots hors-vocabulaire (néologismes).

## 5. Les RNNs

---

## Réseaux Récurrents (RNNs)


Avant les Transformers (2017), les RNNs dominaient le NLP.

**Principe** : traiter les tokens **un par un**, en maintenant un **état caché**  $h_t$ .

```
x1 → [RNN] → h1  
x2 → [RNN] → h2    (h1 alimente h2)  
x3 → [RNN] → h3    (h2 alimente h3)  
⋮
```

**Intuitif** : on lit la phrase mot à mot, la compréhension s'accumule.

# Réseaux Récurrents (RNNs)





## Le problème du gradient qui disparaît

Sur de longues séquences, les gradients se multiplient à chaque pas.

$$\frac{\partial \mathcal{L}}{\partial h_1} = \frac{\partial \mathcal{L}}{\partial h_T} \cdot \prod_{t=2}^T \frac{\partial h_t}{\partial h_{t-1}}$$

Si chaque terme  $< 1 \rightarrow$  le gradient devient exponentiellement **petit**.

Les premiers tokens n'apprennent plus rien.

### Solutions partielles :

- **LSTM** (Hochreiter & Schmidhuber, 1997) — portes de mémoire
- **GRU** (Cho et al., 2014) — version simplifiée du LSTM
- Limitation persistante : traitement **séquentiel**, pas de parallélisation

# 6. Le Transformer

---

"Attention is All You Need"

Vaswani et al., 2017

## L'idée radicale

Se débarrasser de la récurrence.

Au lieu de traiter les tokens un par un, permettre à **chaque token de regarder directement tous les autres** en même temps.

Avantages immédiats :

- **Parallélisation** totale → entraînement massivement accéléré sur GPU
- **Dépendances longue distance** capturées sans dégradation
- **Scalabilité** : plus de paramètres = meilleur modèle (jusqu'à un certain point)

## L'architecture transformer



## Le mécanisme d'Attention

**Intuition** : pour comprendre *"il"* dans *"Le chat s'est couché. Il ronronne."*, le modèle doit faire attention à *"chat"* quelques tokens plus tôt.

Le mécanisme d'attention permet à un modèle de langage de pondérer l'importance relative de chaque mot par rapport aux autres. Concrètement, pour chaque mot, le modèle calcule un score de pertinence avec tous les autres mots, ce qui lui permet de "focaliser" son interprétation sur les parties les plus utiles du contexte.

## Le mécanisme d'Attention

Chaque token produit **3 vecteurs** :

| Vecteur   | Rôle                             |
|-----------|----------------------------------|
| Query (Q) | "Qu'est-ce que je cherche ?"     |
| Key (K)   | "Qu'est-ce que je représente ?"  |
| Value (V) | "Quelle information j'apporte ?" |

**Analogie** : Imagine une bibliothèque : Tu arrives avec une requête (Query) : "Je cherche un livre sur les réseaux de neurones". Chaque livre a une étiquette au dos (Key) : "Machine Learning", "Cuisine", "Histoire"... Le contenu du livre (Value) : c'est ce que tu liras vraiment si tu le choisis.

En pratique les Q, K, V pour chaque tokens sont des vecteurs entraînés pour que les bonnes paires se ressemblent. C'est le modèle qui apprend ce que "chercher" et "proposer" veulent dire.

## Attention — Le calcul

**Score d'attention** entre le token  $i$  et le token  $j$  :

$$\text{score}(i, j) = \text{softmax}\left(\frac{Q_i \cdot K_j}{\sqrt{d_k}}\right)$$


**Sortie** pour le token  $i$  = somme pondérée des valeurs :

$$\text{output}_i = \sum_j \text{score}(i, j) \cdot V_j$$

La division par  $\sqrt{d_k}$  évite que les produits scalaires deviennent trop grands et saturent le softmax.

## Self-Attention (Auto-attention)

Chaque mot d'une séquence calcule **son** attention sur tous les autres mots de cette **même séquence** pour enrichir sa représentation en tenant compte du contexte.





## Self-Attention — Pourquoi ça marche

Tous ces calculs se font **en parallèle** via des multiplications matricielles.

Le modèle ne requiert pas de supervision ou annotation manuelle. Chaque token apprend sa représentation à partir de son contexte.

$$\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) \cdot V$$

**Ce que le modèle apprend** : quels tokens sont pertinents pour chaque position.

Sur la phrase *"La banque a refusé le prêt car elle manquait de fonds"* :

- Pour résoudre *"elle"* → forte attention sur *"banque"*
- Pour résoudre *"fonds"* → forte attention sur *"prêt"* et *"manquait"*

## Multi-Head Attention

Plutôt qu'une seule attention, le Transformer en utilise **plusieurs en parallèle**.

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \cdot W^O$$

Chaque tête peut se **spécialiser** :

- Tête 1 → relations syntaxiques (sujet-verbe)
- Tête 2 → relations sémantiques (synonymes)
- Tête 3 → coréférences (pronom → antécédent)
- ...

GPT-3 : 96 têtes d'attention par couche.

## Encodage positionnel

**Problème** : l'attention est indépendante de l'ordre des tokens !

*"Le chat mange le poisson" = "Le poisson mange le chat" sans correction.*

**Solution** : ajouter un **encodage positionnel** à chaque embedding.

$$\text{embedding\_final} = \text{embedding\_mot} + \text{encodage\_position}$$


Dans le papier original : fonctions sinus/cosinus à différentes fréquences.

Les modèles modernes apprennent souvent ces positions directement (RoPE, ALiBi...).

## Architecture complète



# Architecture complète



- **Encodeur** → comprendre la séquence source (BERT)
- **Décodeur** → générer la séquence cible (GPT, Claude)
- **Encodeur+Décodeur** → traduction, résumé (T5, BART)

# Les deux familles

|           | Encodeur seul           | Décodeur seul             |
|-----------|-------------------------|---------------------------|
| Exemple   | BERT (2018, Google)     | GPT- 1/2/3/4 (OpenAI)     |
| Attention | Bidirectionnelle        | Causale (gauche → droite) |
| Objectif  | Comprendre / classifier | Générer du texte          |
| Tâches    | Classification, NER, QA | Génération, dialogue      |

Les LLMs actuels — **GPT-4, Claude, Llama, Mistral** — sont presque tous des **décodeurs**.

## Quiz 4

Pourquoi les Transformers s'entraînent-ils **plus vite** que les RNNs sur GPU ?

- A) Ils ont moins de paramètres
- B) L'attention calcule toutes les relations en parallèle via opérations matricielles
- C) Ils n'utilisent pas de rétropropagation
- D) Ils traitent les tokens par blocs de 10

## Récapitulatif

Texte brut

↓ tokenisation

Séquence de tokens

↓ embeddings

Vecteurs denses

↓ Transformer (attention)

Représentations contextuelles



## Ce que vous devez retenir

- **Token**  $\neq$  mot. Les LLMs opèrent sur des sous-mots.
- **Lemmatisation**  $\rightarrow$  forme canonique, tient compte du contexte grammatical
- **Word2Vec**  $\rightarrow$  embeddings statiques, capturent la sémantique par le contexte
- **Attention**  $\rightarrow$  chaque token peut regarder tous les autres en parallèle
- **Transformer**  $\rightarrow$  parallélisation (encoding positionnel) + dépendances longue distance

## 🧩 Quiz final — 5 minutes

1. Quelle est la différence entre un token et un mot ?
2. Dans l'attention, à quoi servent Q, K et V ?
  - A) Question, Clé de tri, Valeur d'apprentissage
  - B) Requête, Clé de correspondance, Contenu à agréger ✓
  - C) Ils sont interchangeables
3. Vrai/Faux : Word2Vec résout l'ambiguïté du mot "*batterie*".
4. Pourquoi entraîner sur la prédiction du prochain token est-il une bonne façon d'apprendre le langage ?

## Ressources clés

- 📄 **Word2Vec** — Mikolov et al. (2013) — [arxiv.org/abs/1301.3781](https://arxiv.org/abs/1301.3781)
- 📄 **Attention is All You Need** — Vaswani et al. (2017) — [arxiv.org/abs/1706.03762](https://arxiv.org/abs/1706.03762)
- 📄 **GloVe** — Pennington et al. (2014) — [nlp.stanford.edu/projects/glove](https://nlp.stanford.edu/projects/glove)
- 📄 **LSTM** — Hochreiter & Schmidhuber (1997) — Neural Computation
  
- 🔧 **spaCy** — [spacy.io](https://spacy.io) | **Hugging Face** — [huggingface.co](https://huggingface.co)
- 📖 **CS224n** (Stanford NLP) — cours en ligne gratuit, excellent

**Avant la séance 2** : lire l'abstract de *"Attention is All You Need"*.

## Lab — Aujourd'hui (1h-2h)

### Partie 1 — Pré-traitement avec `spaCy`

Tokeniser, lemmatiser, retirer les stop words sur un jeu de textes.

### Partie 2 — Embeddings BoW & TF-IDF avec `scikit-learn`

Visualiser les vecteurs (PCA), comparer des documents.

### Partie 3 — Word2Vec avec `gensim`

Explorer les analogies et les voisins sémantiques.

### Partie 4 — Premier contact avec les Transformers

Charger un modèle Hugging Face, obtenir des embeddings contextuels.

# Séance 2 — 12 juin

Entraînement : comment construit-on un LLM ?

---

Tokenization · Pré-entraînement à grande échelle · Lois de Chinchilla  
Instruction tuning & RLHF · Évaluation

---

## Lectures conseillées :

Vaswani et al. (2017), "Attention is All You Need" — abstract + intro

---

`celia.nouri@inria.fr`