

# Introduction aux LLMs

Séance 1 : Introduction au traitement automatique des langues et apprentissage machine

---

**ESGI Paris**

Célia Nouri · `celia.nouri@inria.fr`

Semestre 1, 2026–2027

# Plan de la séance

---

2h de cours + lab Python (3h total)

# Au programme aujourd'hui

1. Introduction : qu'est-ce que le TAL ?
  2. Le TAL avant le machine learning
  3. Les bases du machine learning
- **Objectif** : construire une intuition solide sur le TAL (NLP) et le machine learning pour comprendre les LLMs dans les séances suivantes

# À propos de ce cours

- **Volume** : 15h; 4 séances de 3h ou 4h30
- **Format** : 2-3h cours + 30min-1h lab Python
- **Éval** : QCM 40 questions
- **Prérequis** : Python, bases ML, APIs REST

 Questions & bugs : `celia.nouri@inria.fr`

# 1. Introduction

---

# Qu'est-ce que le TAL ?

**TAL** = **T**raitement **A**utomatique des **L**angues (en anglais : *NLP, Natural Language Processing*)

Les langues ou langage naturel (français, anglais, arabe...), à distinguer des langages informatiques (Python, SQL...) qui suivent des règles strictes et non ambiguës.

Deux mots, deux disciplines :

1. **Le langage** → la **linguistique**
2. **Le traitement automatique** → l'**informatique** (statistiques, machine learning)

# (1) Le langage : la linguistique

La **linguistique** = l'étude du langage humain. Quelles sont les règles qui le gouvernent ?

- **Phonologie** : organisation et fonction des sons (les phonèmes) au sein d'une langue particulièreles
- **Morphologie** : la forme des mots (\*« irresponsables » => ir- + respons- + -able- + -s \*)
- **Syntaxe** : l'ordre et la structure des phrases (« *Le chat mange la souris* » ≠ « *La souris mange le chat* »)
- **Sémantique** : le sens des mots et des phrases
- **Pragmatique** : le sens en situation (« *Tu peux ouvrir la fenêtre ?* » est une demande, pas une question)

# Le langage varie et évolue

Le langage est aussi **social et culturel** : il varie selon les régions, les groupes sociaux, les époques et les registres.

- **Variations régionales** : *pain au chocolat / chocolatine* ; « *septante* » (Belgique, Suisse) / « *soixante-dix* » (France) ; « *char* » (Québec) = voiture
- **Registres** : « *Je n'ai pas compris* » / « *J'ai pas capté* »
- **Évolution** : nouveaux mots (« *liker* », « *ghoster* »), sens qui changent, langage SMS et réseaux sociaux
- **Culture** : expressions (« *Avoir le cafard* », « *Poser un lapin* »)

# Le langage est ambigu par nature

Le sens n'est pas uniquement contenu dans les mots eux-mêmes : il dépend de la syntaxe, du contexte discursif, de la situation d'énonciation, des connaissances du monde et des intentions du locuteur, etc...

## Ambiguïté lexicale

- *"Donne-moi la batterie."*

L'instrument de musique ? La pile électrique ?

## Connaissance du monde

- *"Marc s'est assis, a regardé le menu."*

Sous-entendu : Marc est au restaurant.

## Ironie / Sarcasme

- Après 2h de retard : *"Super, t'es vraiment ponctuel."*

Sens réel : critique / sens littéral : compliment.

## (2) Le traitement automatique

Traitement automatique par ordinateur, exécute des suites d'instructions pour effectuer des calculs arithmétiques et des opérations logiques sur des chiffres binaires (0/1).

Comment faire manipuler du langage par un ordinateur?


- **Avant le machine learning** : on **compte** et on applique des **règles écrites à la main**  
*Statistiques sur les mots, stop words, stemming, lemmatisation, expressions régulières, POS tagging, analyse en dépendances...*
- **Machine learning** : la machine **apprend** les régularités à partir d'exemples  
*Représenter les mots par des vecteurs (Word2Vec)*
- **Deep learning** : des réseaux de neurones profonds  
*RNN, puis Transformers, puis LLMs*
- **Aujourd'hui** : intégration d'outils, mémoire, et systèmes agentiques

# Tâches classiques du TAL

| Tâche                   | Exemple                                                                         |
|-------------------------|---------------------------------------------------------------------------------|
| Étiquetage de séquences | Repérer les noms de personnes, de lieux (NER), la nature des mots (POS tagging) |
| Classification de texte | Ce mail est-il un spam ? Cet avis est-il positif ?                              |
| Traduction automatique  | « <i>Bonjour</i> » → « <i>Hello</i> »                                           |
| Résumé automatique      | Condenser un article en 3 phrases                                               |
| Question-réponse        | « <i>Quelle est la capitale de l'Australie ?</i> »                              |
| Génération de texte     | Rédiger un mail, écrire du code                                                 |

# Les données textuelles

- **Discussion** : Quelles sont les sources de données utilisées par le TAL.




# Les sources de données en TAL



# Historique des avancées en TAL

| Période           | Approche                              | Repères                                               |
|-------------------|---------------------------------------|-------------------------------------------------------|
| <b>1950–1980s</b> | Règles écrites à la main (symbolique) | ELIZA (1966), grammaires formelles                    |
| <b>1990–2000s</b> | Statistiques : on compte les mots     | <i>n</i> -grammes, Zipf, <i>bag of words</i> , TF-IDF |
| <b>2013</b>       | Machine learning : embeddings         | Word2Vec                                              |
| <b>2014–2017</b>  | Deep learning : réseaux récurrents    | RNN, LSTM, seq2seq                                    |
| <b>2017</b>       | Transformers                          | <i>Attention Is All You Need</i>                      |
| <b>2018–2022</b>  | Modèles pré-entraînés, LLMs           | BERT, GPT-3, ChatGPT (fin 2022)                       |
| <b>2023–...</b>   | Raisonnement, outils, agents          | Toolformer, o1, DeepSeek-R1, agents                   |

# Historique des avancées en TAL



# Le TAL en 2025-2026

How to write a course for advanced NLP?




Writing a course for **advanced NLP (Natural Language Processing)** involves a thoughtful balance of theory, practical applications, and emerging trends in the field. You will need to structure the course to cover both foundational knowledge and the latest advancements in NLP. Below is a guide to help you develop a comprehensive and effective course.

## Step 1: Define Course Objectives

Start by identifying the key objectives for the course. For example, students should be able to:

# Le TAL en 2025-2026



# Le TAL en 2025-2026

- *Génère une image de l'école d'informatique en alternance à Paris (ESGI) avec le logo de l'école et une bannière.*



# Le TAL en 2025-2026





6 

TOUT

RECHERCHER

IMAGES

VIDÉOS

CARTES

ACTUALITÉS

COPILOT

PLUS

À PROPOS DES RÉSULTATS DE RECHERCHE

 Copilot Search



D'accord 😊 Je vais te préparer un **cours clair et structuré sur le NLP (Traitement Automatique du Langage Naturel)**, adapté pour un apprentissage progressif.

On va le découper en **modules**, avec définitions, concepts clés, exemples et exercices.

### Cours de NLP – Introduction et Fondamentaux

#### Module 1 : Introduction au NLP

- **Définition** : Le NLP (Natural Language Processing) est un domaine de l'IA qui permet aux machines de comprendre, interpréter et générer du langage humain.
- **Applications courantes** :
  - Chatbots et assistants vocaux
  - Traduction automatique



Adapter le contenu

 Ré...

Modifier la longueur ▾

Modifier la tonalité ▾


Essayer d'autres m... ▾

Techniques avancées de NLP

Applications pratiques du NLP

Outils open source NLP

# Le TAL en 2025-2026



# Organisation des séances



Célia Nouri  
celia.nouri@inria.fr

# Organisation des séances

- Objectives
  - **Connaissances** : comprendre l'architecture et le processus d'entraînement d'un LLM moderne, et les avancées récentes dans le domaine du TAL.
  - **Mise en practice** : Concevoir un système intégrant des LLMs modernes (RAG : Retrieval-Augmented Generation, agents) fonctionnel
  - **Distance Critique** : Comprendre les limites et problèmes actuels liés aux LLMs, et analyser les méthodes et avancées en maintenant une distance critique.

# Organisation des séances

- **Séance 1 (Aujourd'hui)**: Fondations : Introduction TAL et ML
- **Séance 2 (29 octobre)**: Word Embeddings, Tokenization, Transformers
- **Séance 3 (30 octobre)**: Entraînement: pré-entraînement et post-entraînement, Utilisation et LLM-augmentés : Prompting, RAG
- **Séance 5 (27 novembre)**: Toolformer, Architectures agentiques + Modèles de raisonnement (bonus: Multimodalité)
- **Examen**: QCM final 40 questions

## **2. Le TAL avant le machine learning**

---

# Étudier le langage automatiquement

Avant le machine learning, on étudie le langage **avec des règles et des statistiques** :

1. **Trouver des patterns** dans les textes
2. **Les associer à des phénomènes** qu'on veut étudier ou détecter

# La loi de Zipf


Une régularité statistique observée dans **toutes** les langues : la fréquence d'un mot est **inversement proportionnelle à son rang**.

$$f(r) \propto \frac{1}{r}$$

- Le mot le plus fréquent apparaît ~2× plus que le 2ème, ~3× plus que le 3ème...
- ~100 mots couvrent ~50% de tout texte
- La grande majorité du vocabulaire est **très rare**

**Conséquence** : les mots les plus fréquents (« *le* », « *de* », « *et* ») sont partout, donc ne nous apprennent rien sur le sujet d'un texte.

# La loi de Zipf



## Un exemple d'étude de TAL

**Questions** : quels verbes/adjectifs sont les plus associés aux personnages **féminins** ou **masculins** dans un roman ?

- Article : **Gender Bias in French Literature** (Vianne, Dupont, Barré, CHR 2023)

# Étude : biais de genre dans la littérature française

- **Corpus** : 2 942 romans français de 1811 à 2020
- **Objectif** : les personnages sont-ils décrits différemment selon leur genre ?
- **Méthode** :
  - i. Repérer les personnages et leurs mentions (*il, elle, Jeanne...*)
  - ii. Analyser chaque phrase avec spaCy (**lemmatisation, POS tagging, analyse en dépendances**)
  - iii. Extraire les **verbes** et **adjectifs** liés à chaque personnage
  - iv. **Compter** les lemmes par personnage (*bag of words*)

# Part-of-speech (POS) tagging

Détecter automatiquement la fonction grammaticale de chaque mot dans un texte.

**Table 4**  
Example of a parsed sentence in our format. Some headings had to be abbreviated to fit the paper. "Idx" means "index", "ChId" means "character id", "G" means "gender". The sentence translates to "Renaud caresses me with one of these intelligent glances that bring me back to him."

| Idx | Word         | Lemma       | POS   | Head | Dep       | ChId | G |
|-----|--------------|-------------|-------|------|-----------|------|---|
| 0   | Renaud       | Renaud      | PROPN | 2    | nsubj     | 4    | m |
| 1   | me           | me          | PRON  | 2    | obj       | 1    | f |
| 2   | caresse      | caresse     | VERB  | 2    | root      | 0    | u |
| 3   | d'           | de          | ADP   | 4    | case      | 0    | u |
| 4   | un           | un          | PRON  | 2    | obl:mod   | 0    | u |
| 5   | de           | de          | ADP   | 7    | case      | 0    | u |
| 6   | ces          | ce          | DET   | 7    | det       | 0    | u |
| 7   | regards      | regard      | NOUN  | 4    | nmod      | 0    | u |
| 8   | intelligents | intelligent | ADJ   | 7    | amod      | 0    | u |
| 9   | qui          | qui         | PRON  | 11   | nsubj     | 0    | u |
| 10  | me           | me          | PRON  | 11   | obj       | 1    | f |
| 11  | ramènent     | ramener     | VERB  | 7    | acl:relcl | 0    | u |
| 12  | à            | à           | ADP   | 13   | case      | 0    | u |
| 13  | lui          | lui         | PRON  | 11   | obl:arg   | 4    | m |

# Stop words

**Stop words** = mots si fréquents qu'ils ne portent pas de sens discriminant.

*le, la, les, un, une, des, de, du, et, ou, est, à, dans, pour, que, qui, ce, il, elle, je, tu, ne, pas*

On cherche à les retirer pour de nombreuses tâches de TAL.

**Exemple** : on cherche les mots les plus associés au genre masculin ou féminin, en comptant ses mots.

```
# Exemple avec spaCy  
[token for token in doc if not token.is_stop]
```

# Stemming vs Lemmatisation

Un même mot existe sous plusieurs formes : **pluriel, masculin/féminin, conjugaison, suffixes, préfixes.**

*manger, mangeons, mangeait, mangé · heureux, heureuse, heureuses · lait, laitier, laiterie*

Une même **racine** = un même **sens**. On veut les regrouper pour compter correctement.

**Stemming** : couper la fin, rapide mais approximatif


```
"courais", "courons", "courir" → "cour" ← pas un vrai mot !
```

**Lemmatisation** : forme canonique, tient compte du contexte grammatical, mais plus coûteux

```
"courais", "courons", "courir" → "courir"  
"meilleures", "meilleur" → "bon" ← le lemme de "meilleur" !
```

Librairie recommandée : **spaCy** (Python)

# Résultats : des verbes genrés



**Figure 3:** Comparison of the masculinity or femininity of action verbs in the corpus. A positive value indicates a stronger association with male characters, while a negative value indicates a stronger association with female characters. In parentheses are their English translations.

- **Féminin** : *pleurer, aimer, rire, regretter, rêver* : expression des **émotions**
- **Masculin** : *tirer, découvrir, marcher, sortir* : verbes d'**action**
- Score d'agentivité (sujet vs objet de la phrase) : **0,70** pour les hommes, **0,64** pour les femmes
- Un simple **comptage de lemmes** met en évidence des stéréotypes présents dans des centaines de romans.

# Expressions régulières (regex)

Une **regex** décrit un **pattern** de texte, pour retrouver automatiquement des structures.

**Exemple** : extraire les numéros de téléphone, les adresses et les emails d'un texte.

```
import re

texte = "Marie, 12 bis rue de la Paix, 75002 Paris. Tél : 06.12.34.56.78"

re.findall(r'(?:\+33\s?|0)[1-9](?:[ .-]?[0-9]{2}){4}', texte)
# → ['06.12.34.56.78']          (numéros de téléphone)

re.findall(r"\d{1,3}(?: bis| ter)? (?:rue|avenue|boulevard|place) [\w' -]+, \d{5} [A-ZÉ][\w-]+", texte)
# → ['12 bis rue de la Paix, 75002 Paris'] (adresses)

re.findall(r'[\w.-]+@[[\w.-]+\.\w+', texte)
# → emails
```

## Quiz 1

**Le lemme du mot "allées"** (dans *"les allées du parc"*) est :

- **A)** "allé"
- **B)** "aller"
- **C)** "allée"
- **D)** "alle"

→ *Réponse dans 30 secondes*

## Quiz 1 : Réponse

Réponse : C : "allée"

"Allées" est ici un **nom commun** (*les allées du parc*).

Le lemme d'un nom commun est son singulier : **allée**.

Si c'était le **participe passé** du verbe *aller* ("*elles sont allées*"),  
le lemme serait **aller**.

- **Le contexte grammatical change le lemme** : c'est pourquoi la lemmatisation demande une analyse syntaxique, pas juste une règle de troncature.

# **3. Introduction au Machine Learning**

---

# C'est quoi, l'apprentissage machine ?

Au lieu d'écrire les règles à la main, on **laisse la machine les découvrir à partir de données exemples**.

Un modèle de ML = une **fonction paramétrique** qui **modélise les données** :

$$\hat{y} = f(x ; \theta)$$

- $x$  = entrée (texte, image...)
- $\hat{y}$  = prédiction du modèle
- $\theta$  = **paramètres** (poids) : variables que l'on ajuste ; de quelques dizaines à des milliards

**Apprendre** = optimiser  $\theta$  pour que la fonction **reproduise les données**, c'est-à-dire que  $\hat{y}$  soit proche de la vraie réponse  $y$ .

# La méthode en 4 étapes

1. **Source de données** : collecter des exemples
  2. **Définir la tâche d'apprentissage** par une **fonction paramétrique**  $f(x ; \theta)$  et une mesure de l'erreur (la fonction de perte)
  3. **Optimiser** la fonction sur des données d'**entraînement**
  4. **Tester la généralisation** sur des données qu'elle n'a jamais vues
- Ce qui compte n'est pas d'obtenir un bon score sur les exemples déjà vus (le modèle pourrait simplement mémoriser les données d'entraînement), mais sur **de nouveaux exemples**.

# Séparer les données : train / validation / test

On découpe les données en **trois ensembles** :

| Ensemble                             | Rôle                                                                 | Analogie                      |
|--------------------------------------|----------------------------------------------------------------------|-------------------------------|
| <b>Entraînement</b> ( <i>train</i> ) | Optimiser les paramètres $\theta$                                    | Les exercices qu'on travaille |
| <b>Validation</b>                    | Choisir les réglages (hyperparamètres), détecter le surapprentissage | Les examens blancs            |
| <b>Test</b>                          | Mesure finale, utilisée <b>une seule fois</b>                        | L'examen final                |

Exemple de découpage : **80 % / 10 % / 10 %**.

Règle d'or: ne jamais entrainer le modèle sur les données de test, sinon le score est truqué.

# Supervisé vs non supervisé

|          | Supervisé                                           | Non supervisé                            |
|----------|-----------------------------------------------------|------------------------------------------|
| Données  | Entrées $x$ <b>avec</b> la réponse $y$ (labels)     | Entrées $x$ <b>sans</b> label            |
| Objectif | Prédire $y$ à partir de $x$                         | Découvrir une structure dans les données |
| Exemples | Détection de spam, traduction, analyse de sentiment | Clustering, Word2Vec                     |

Les labels demandent souvent du **travail humain** (annotation) qui est très coûteux. Les algorithmes non supervisé fonctionnent sans label, mais ne sont pas adaptés pour toutes les tâches.

# Exemple supervisé : détecter les spams

**Tâche** : dire si un email est un spam.

1. **Données** : 5 000 emails
2. **Labels** : chaque email est annoté **spam** ( $y = 1$ ) ou **non-spam** ( $y = 0$ )
3. **Fonction** :  $f(x = \text{email}) = y = \text{label}$

| Email                                       | Label    |
|---------------------------------------------|----------|
| « Gagnez 1000 € maintenant, cliquez ici ! » | spam     |
| « Réunion de projet demain à 10h »          | non-spam |

# Spam : représenter l'email par des nombres

Un ordinateur ne calcule que sur des **nombres**. On compte les mots (comme dans la partie 2) :

$x$  = vecteur des **occurrences de chaque mot** du vocabulaire

|               |        |         |         |        |     |            |
|---------------|--------|---------|---------|--------|-----|------------|
| vocabulaire : | gagnez | cliquez | réunion | demain | ... |            |
| email 1 :     | 1      | 1       | 0       | 0      | ... | (spam)     |
| email 2 :     | 0      | 0       | 1       | 1      | ... | (non-spam) |

$$\hat{y} = \sigma(w \cdot x + b) \in [0, 1]$$

- $w$  : un **poids par mot** (« gagnez » → *poids élevé* : signal de spam)
- $\sigma$  : transforme le score en **probabilité** d'être un spam
- **Paramètres**  $\theta = (w, b)$  : avec un vocabulaire de 10 000 mots, **10 001 paramètres** à optimiser (contre des milliards pour un LLM)

# La fonction de perte (Loss)

On mesure l'erreur du modèle avec une **fonction de perte**  $\mathcal{L}$ .

Pour une classification binaire (ex. spam / pas spam) :

$$\mathcal{L} = - \left[ y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y}) \right]$$

C'est la **cross-entropy**. Plus  $\mathcal{L}$  est faible, mieux le modèle prédit.

Un email est un spam ( $y = 1$ ) :

- le modèle dit  $\hat{y} = 0,9 \rightarrow \mathcal{L} \approx 0,11$  (petite erreur)
- le modèle dit  $\hat{y} = 0,1 \rightarrow \mathcal{L} \approx 2,30$  (grosse erreur)

**Objectif** : trouver  $\theta^*$  tel que  $\mathcal{L}$  soit minimale sur les données d'entraînement.

**Discussion** : comment trouver le minimum (s'il existe) de la fonction de perte ?

# Descente de gradient

**Entraîner** le filtre à spam = trouver les  $\theta$  qui minimisent la perte sur les **80 % de données d'entraînement**.

Pour les réseaux de neurones, la fonction de perte est très complexe, non linéaire et multidimensionnelle : impossible de résoudre directement "dérivée = 0".

Idée : se déplacer dans la direction qui **réduit** la fonction de perte.

$$\theta \leftarrow \theta - \alpha \cdot \frac{\partial \mathcal{L}}{\partial \theta}$$

- $\alpha$  = **learning rate** (taux d'apprentissage), un hyperparamètre crucial
- $\frac{\partial \mathcal{L}}{\partial \theta}$  = gradient = direction de la pente ascendante
- on se déplace à chaque étape de l'apprentissage en direction -  $\frac{\partial \mathcal{L}}{\partial \theta} x \alpha$

**Analogie** : vous êtes dans le brouillard sur une montagne. Vous voulez descendre dans la vallée. À chaque pas, vous regardez la pente sous vos pieds et avancez dans la direction la plus raide vers le **bas**.

# Rétropropagation (Backpropagation)

Dans un réseau de neurones, le gradient se calcule par **rétropropagation** :

Forward pass :

$x \rightarrow [\text{Couche 1}] \rightarrow [\text{Couche 2}] \rightarrow [\text{Couche 3}] \rightarrow \hat{y} \rightarrow L$

Backward pass (règle de la chaîne) :

$\partial L / \partial \theta_1 \leftarrow \partial L / \partial \theta_2 \leftarrow \partial L / \partial \theta_3 \leftarrow \partial L / \partial \hat{y}$

La **règle de la chaîne** permet de calculer les gradients couche par couche, de la sortie vers l'entrée.

PyTorch / TensorFlow font ça automatiquement (**autograd**).

# Surapprentissage (Overfitting)

Le modèle **mémorise** les données d'entraînement au lieu d'en apprendre les patterns.

On le détecte en comparant les scores sur l'**entraînement** et sur la **validation / le test**.

|             | Accuracy train | Accuracy test |
|-------------|----------------|---------------|
| Bon modèle  | 92%            | 89%           |
| Overfitting | 99%            | 62%           |

## Solutions courantes :

- **Dropout** : désactiver des neurones aléatoirement pendant l'entraînement
- **Weight decay** : pénaliser les poids trop grands ( $L_2$  régularisation)
- **Early stopping** : arrêter quand la validation stagne
- **Plus de données** : (et des données plus diverses et représentatives), le remède le plus efficace

## Spam : évaluer sur les données de test

Après l'entraînement (descente de gradient sur les 80 % d'entraînement), on **évalue sur les 10 % de test**, jamais vus par le modèle :

- **Accuracy** : part des emails correctement classés
- **Précision / rappel** : combien de vrais spams détectés, combien de fausses alertes
- Un bon filtre à spam n'est pas celui qui connaît ses 4 000 emails d'entraînement, mais celui qui classe correctement **les emails de demain**.

# Exemple non supervisé : découvrir des groupes

Pas de labels : on donne seulement les données, la machine **cherche une structure**.

- **Clustering** : regrouper des articles de presse par thème (sport, politique, culture...) **sans** avoir dit quels thèmes existent
- **Word2Vec** : apprendre à représenter les mots par des vecteurs en observant quels mots apparaissent ensemble → **prochaine partie**

Le non supervisé est à la base des **LLMs** : ils apprennent à partir de quantités énormes de texte **sans annotation manuelle** (séance 2).

## Quiz 2

Un modèle atteint **99% d'accuracy** sur les données d'entraînement et **62%** sur les données de test.

Que se passe-t-il ?

- **A)** Le modèle est parfait, 99% c'est excellent
- **B)** Il y a du surapprentissage (*overfitting*)
- **C)** Les données de test sont mauvaises
- **D)** Le learning rate est trop élevé

# Séance 2 : 29 octobre

Représentations vectorielles du texte : comment traduire des mots en vecteurs ?

---

Vecteurs de mots · Bag-of-Words · Word2Vec ·

Architectures traitement du texte · RNNs · Transformers

---

## **Lectures conseillées :**

Vaswani et al. (2017), "Attention is All You Need" : abstract + intro

---

`celia.nouri@inria.fr`