

Introduction aux LLMs

Séance 1 : Introduction au traitement automatique des langues et apprentissage machine

ESGI Paris

Célia Nouri · `celia.nouri@inria.fr`

Semestre 1, 2026–2027

Plan de la séance

2h de cours + lab Python (3h total)

Au programme aujourd'hui

1. Introduction : qu'est-ce que le TAL ?
 2. Le TAL avant le machine learning
 3. Les bases du machine learning
- **Objectif** : construire une intuition solide sur le TAL (NLP) et le machine learning pour comprendre les LLMs dans les séances suivantes

À propos de ce cours

|---|---|

| **Volume** | 15h; 4 séances de 3h ou 4h30 |

| **Format** | 2-3h cours + 30min-1h lab Python |

| **Éval** | QCM 40 questions |

| **Prérequis** | Python, bases ML, APIs REST |



Questions & bugs : `celia.nouri@inria.fr`

1. Introduction

Qu'est-ce que le TAL ?

TAL = **T**raitement **A**utomatique des **L**angues (en anglais : *NLP, Natural Language Processing*)

Les langues ou langage **naturel** (français, anglais, arabe...), à distinguer des langages **informatiques** (Python, SQL...) qui suivent des règles strictes et non ambiguës.

Deux mots, deux disciplines :

1. **Le langage** → la **linguistique**
2. **Le traitement automatique** → l'**informatique** (statistiques, machine learning)

(1) Le langage : la linguistique

La **linguistique** = l'étude scientifique du langage humain. Quelles sont les règles qui le gouvernent ?

- **Phonologie** : organisation et fonction des sons (les phonèmes) au sein d'une langue particulièreles
- **Morphologie** : la forme des mots (« *irresponsables* » = « *ir-* + *respons-* + *-able-* + *-s* »)
- **Syntaxe** : l'ordre et la structure des phrases (« *Le chat mange la souris* » ≠ « *La souris mange le chat* »)
- **Sémantique** : le sens des mots et des phrases
- **Pragmatique** : le sens en situation (« *Tu peux ouvrir la fenêtre ?* » est une demande, pas une question)

Le langage varie et évolue

Le langage est aussi **social et culturel** : il varie selon les régions, les groupes sociaux, les époques et les registres.

- **Variations régionales** : *pain au chocolat / chocolatine* ; « *septante* » (Belgique, Suisse) / « *soixante-dix* » (France) ; « *char* » (Québec) = voiture
- **Registres** : « *Je n'ai pas compris* » / « *J'ai pas capté* »
- **Évolution** : nouveaux mots (« *liker* », « *ghoster* »), sens qui changent, langage SMS et réseaux sociaux
- **Culture** : expressions (« *Avoir le cafard* », « *Poser un lapin* »)

Le langage est ambigu par nature

Le sens n'est pas uniquement contenu dans les mots eux-mêmes : il dépend de la syntaxe, du contexte discursif, de la situation d'énonciation, des connaissances du monde et des intentions du locuteur, etc...

Ambiguïté lexicale

- *"Donne-moi la batterie."*

L'instrument de musique ? La pile électrique ?

Ambiguïté syntaxique

- *"J'ai vu l'homme avec les jumelles."*

Qui a les jumelles : moi ou l'homme ?

Connaissance du monde

- *"Marc s'est assis, a regardé le menu."*

Sous-entendu : Marc est au restaurant.

Ironie / Sarcasme

INTRODUCTION AUX LLMS — ESGI PARIS

- Après 2h de retard : *"Super t'es vraiment ponctuel"*

(2) Le traitement automatique

Traitement automatique par ordinateur, exécute des suites d'instructions pour effectuer des calculs arithmétiques et des opérations logiques sur des chiffres binaires (0/1).

Comment faire manipuler du langage par un ordinateur?


- **Avant le machine learning** : on **compte** et on applique des **règles écrites à la main**
Statistiques sur les mots, stop words, stemming, lemmatisation, expressions régulières, POS tagging, analyse en dépendances...
- **Machine learning** : la machine **apprend** les régularités à partir d'exemples
Représenter les mots par des vecteurs (Word2Vec)
- **Deep learning** : des réseaux de neurones profonds
RNN, puis Transformers, puis LLMs
- **Aujourd'hui** : les LLMs deviennent des **modèles de raisonnement**, utilisent des **outils** et agissent comme des **agents**

Tâches classiques du TAL

Tâche	Exemple
Classification de texte	Ce mail est-il un spam ? Cet avis est-il positif ?
Étiquetage de séquences	Repérer les noms de personnes, de lieux (NER), la nature des mots (POS tagging)
Traduction automatique	« <i>Bonjour</i> » → « <i>Hello</i> »
Résumé automatique	Condenser un article en 3 phrases
Question-réponse	« <i>Quelle est la capitale de l'Australie ?</i> »
Génération de texte	Rédiger un mail, écrire du code

Les données textuelles

- **Discussion** : Quelles sont les sources de données utilisées par le TAL.




Les sources de données en TAL



Historique des avancées en TAL

Période	Approche	Repères
1950–1980s	Règles écrites à la main (symbolique)	ELIZA (1966), grammaires formelles
1990–2000s	Statistiques : on compte les mots	<i>n</i> -grammes, Zipf, <i>bag of words</i> , TF-IDF
2013	Machine learning : embeddings	Word2Vec
2014–2017	Deep learning : réseaux récurrents	RNN, LSTM, seq2seq
2017	Transformers	<i>Attention Is All You Need</i>
2018–2022	Modèles pré-entraînés, LLMs	BERT, GPT-3, ChatGPT (fin 2022)
2024–...	Raisonnement, outils, agents	o1, DeepSeek-R1, agents avec outils

Historique des avancées en TAL



Le TAL en 2025-2026

How to write a course for advanced NLP?




Writing a course for **advanced NLP (Natural Language Processing)** involves a thoughtful balance of theory, practical applications, and emerging trends in the field. You will need to structure the course to cover both foundational knowledge and the latest advancements in NLP. Below is a guide to help you develop a comprehensive and effective course.

Step 1: Define Course Objectives

Start by identifying the key objectives for the course. For example, students should be able to:

Le TAL en 2025-2026



Le TAL en 2025-2026

- *Génère une image de l'école d'informatique en alternance à Paris (ESGI) avec le logo de l'école et une bannière.*



Le TAL en 2025-2026



×  

6 

TOUT

RECHERCHER

IMAGES

VIDÉOS

CARTES

ACTUALITÉS

COPILOT

PLUS

À PROPOS DES RÉSULTATS DE RECHERCHE

 Copilot Search

D'accord 😊 Je vais te préparer un **cours clair et structuré sur le NLP (Traitement Automatique du Langage Naturel)**, adapté pour un apprentissage progressif.

On va le découper en **modules**, avec définitions, concepts clés, exemples et exercices.

Cours de NLP – Introduction et Fondamentaux

Module 1 : Introduction au NLP

- **Définition** : Le NLP (Natural Language Processing) est un domaine de l'IA qui permet aux machines de comprendre, interpréter et générer du langage humain.
- **Applications courantes** :
 - Chatbots et assistants vocaux
 - Traduction automatique

 Adapter le contenu

 Ré...

Modifier la longueur ▾

Modifier la tonalité ▾


Essayer d'autres m... ▾

Techniques avancées de NLP

Applications pratiques du NLP

Outils open source NLP

Le TAL en 2025-2026



Organisation des séances



Célia Nouri
celia.nouri@inria.fr

Organisation des séances

- Objectives
 - **Connaissances** : comprendre l'architecture et le processus d'entraînement d'un LLM moderne, et les avancées récentes dans le domaine du TAL.
 - **Mise en practice** : Concevoir un système intégrant des LLMs modernes (RAG : Retrieval-Augmented Generation, agents) fonctionnel
 - **Distance Critique** : Comprendre les limites et problèmes actuels liés aux LLMs, et analyser les méthodes et avancées en maintenant une distance critique.

Organisation des séances

- **Séance 1 (Aujourd'hui)**: Fondations : Introduction TAL et ML
- **Séance 2 (29 octobre)**: Embeddings, Transformers, Tokenization, Pré-entraînement
- **Séance 3 (30 octobre)**: Entraînement: Pré-entraînement + Post-entraînement, Utilisation et LLM-augmentés : Prompting, RAG
- **Séance 5 (27 novembre)**: Agents : Toolformer, Architectures agentiques + Modèles de raisonnement (bonus: Multimodalité)
- **Examen**: QCM final 40 questions

2. Le TAL avant le machine learning

Étudier le langage automatiquement

Une idée simple : compter

Avant le machine learning, on étudie le langage **avec des règles et des statistiques** :

1. **Trouver des patterns** dans les textes
2. **Les associer à des phénomènes** qu'on veut étudier ou détecter

La loi de Zipf


Une régularité statistique observée dans **toutes** les langues : la fréquence d'un mot est **inversement proportionnelle à son rang**.

$$f(r) \propto \frac{1}{r}$$

- Le mot le plus fréquent apparaît ~2× plus que le 2ème, ~3× plus que le 3ème...
- ~100 mots couvrent ~50% de tout texte
- La grande majorité du vocabulaire est **très rare**

Conséquence : les mots les plus fréquents (« *le* », « *de* », « *et* ») sont partout, donc ne nous apprennent rien sur le sujet d'un texte.

La loi de Zipf



Un exemple d'étude de TAL

Questions : quels verbes/adjectifs sont les plus associés aux personnages **féminins** ou **masculins** dans un roman ?

- Article : **Gender Bias in French Literature** (Vianne, Dupont, Barré, CHR 2023)

Étude : biais de genre dans la littérature française

- **Corpus** : 2 942 romans français de 1811 à 2020
- **Objectif** : les personnages sont-ils décrits différemment selon leur genre ?
- **Méthode** :
 - i. Repérer les personnages et leurs mentions (*il, elle, Jeanne...*)
 - ii. Analyser chaque phrase avec spaCy (**lemmatisation, POS tagging, analyse en dépendances**)
 - iii. Extraire les **verbes** et **adjectifs** liés à chaque personnage
 - iv. **Compter** les lemmes par personnage (*bag of words*)

Part-of-speech (POS) tagging

Détecter automatiquement la fonction grammaticale de chaque mot dans un texte.

Table 4
Example of a parsed sentence in our format. Some headings had to be abbreviated to fit the paper. "Idx" means "index", "ChId" means "character id", "G" means "gender". The sentence translates to "Renaud caresses me with one of these intelligent glances that bring me back to him."

Idx	Word	Lemma	POS	Head	Dep	ChId	G
0	Renaud	Renaud	PROPN	2	nsubj	4	m
1	me	me	PRON	2	obj	1	f
2	caresse	caresse	VERB	2	root	0	u
3	d'	de	ADP	4	case	0	u
4	un	un	PRON	2	obl:mod	0	u
5	de	de	ADP	7	case	0	u
6	ces	ce	DET	7	det	0	u
7	regards	regard	NOUN	4	nmod	0	u
8	intelligents	intelligent	ADJ	7	amod	0	u
9	qui	qui	PRON	11	nsubj	0	u
10	me	me	PRON	11	obj	1	f
11	ramènent	ramener	VERB	7	acl:relcl	0	u
12	à	à	ADP	13	case	0	u
13	lui	lui	PRON	11	obl:arg	4	m

Stop words

Stop words = mots si fréquents qu'ils ne portent pas de sens discriminant.

le, la, les, un, une, des, de, du, et, ou, est, à, dans, pour, que, qui, ce, il, elle, je, tu, ne, pas

On cherche à les retirer pour de nombreuses tâches de TAL.

Exemple : on cherche les mots les plus associés au genre masculin ou féminin, en comptant ses mots.

```
# Exemple avec spaCy  
[token for token in doc if not token.is_stop]
```

Stemming vs Lemmatisation

Un même mot existe sous plusieurs formes : **pluriel, masculin/féminin, conjugaison, suffixes, préfixes.**

manger, mangeons, mangeait, mangé · heureux, heureuse, heureuses · lait, laitier, laiterie

Une même **racine** = un même **sens**. On veut les regrouper pour compter correctement.

Stemming : couper la fin, rapide mais approximatif

```
"courais", "courons", "courir" → "cour" ← pas un vrai mot !
```

Lemmatisation : forme canonique, tient compte du contexte grammatical, mais plus coûteux

```
"courais", "courons", "courir" → "courir"  
"meilleures", "meilleur" → "bon" ← le lemme de "meilleur" !
```

Librairie recommandée : **spaCy** (Python)

Résultats : des verbes genrés




Figure 3: Comparison of the masculinity or femininity of action verbs in the corpus. A positive value indicates a stronger association with male characters, while a negative value indicates a stronger association with female characters. In parentheses are their English translations.

- **Féminin** : *pleurer, aimer, rire, regretter, rêver* : expression des **émotions**
- **Masculin** : *tirer, découvrir, marcher, sortir* : verbes d'**action**
- *aimer* apparaît pour **44 %** des personnages féminins contre **25 %** des masculins
- Score d'agentivité (sujet vs objet de la phrase) : **0,70** pour les hommes, **0,64** pour les femmes

Expressions régulières (regex)

Une **regex** décrit un **pattern** de texte, pour retrouver automatiquement des structures.

Exemple : extraire les numéros de téléphone, les adresses et les emails d'un texte.

```
import re

texte = "Marie, 12 bis rue de la Paix, 75002 Paris. Tél : 06.12.34.56.78"

re.findall(r'(?:\+33\s?|0)[1-9](?:[ .-]?[0-9]{2}){4}', texte)
# → ['06.12.34.56.78'] (numéros de téléphone)

re.findall(r"\d{1,3}(?: bis| ter)? (?:rue|avenue|boulevard|place) [\w'-]+, \d{5} [A-ZÉ][\w-]+", texte)
# → ['12 bis rue de la Paix, 75002 Paris'] (adresses)

re.findall(r'[\w.-]+@[ \w.-]+\.\w+', texte)
# → emails
```

Quiz 1

Le lemme du mot "allées" (dans *"les allées du parc"*) est :

- **A)** "allé"
- **B)** "aller"
- **C)** "allée"
- **D)** "alle"

→ *Réponse dans 30 secondes*

Quiz 1 : Réponse

Réponse : C : "allée"

"Allées" est ici un **nom commun** (*les allées du parc*).

Le lemme d'un nom commun est son singulier : **allée**.

Si c'était le **participe passé** du verbe *aller* ("*elles sont allées*"),
le lemme serait **aller**.

- **Le contexte grammatical change le lemme** : c'est pourquoi la lemmatisation demande une analyse syntaxique, pas juste une règle de troncature.

3. Introduction au Machine Learning

C'est quoi, l'apprentissage machine ?

Au lieu d'écrire les règles à la main, on **laisse la machine les découvrir à partir de données exemples**.

Un modèle de ML = une **fonction paramétrique** qui **modélise les données** :

$$\hat{y} = f(x ; \theta)$$

- x = entrée (texte, image...)
- $\hat{y}$ = prédiction du modèle
- θ = **paramètres** (poids) : variables que l'on ajuste ; de quelques dizaines à des milliards

Apprendre = optimiser θ pour que la fonction **reproduise les données**, c'est-à-dire que $\hat{y}$ soit proche de la vraie réponse y .

La méthode en 3 étapes

1. **Source de données** : collecter des exemples
 2. **Définir la tâche d'apprentissage** par une **fonction paramétrique** $f(x; \theta)$ et une mesure de l'erreur (la fonction de perte)
 3. **Optimiser** la fonction sur des données d'**entraînement**, puis **tester la généralisation** sur des données qu'elle n'a jamais vues
- Ce qui compte n'est pas d'obtenir un bon score sur les exemples déjà vus (le modèle pourrait simplement mémoriser les données d'entraînement), mais sur **de nouveaux exemples**.

Séparer les données : train / validation / test

On découpe les données en **trois ensembles** :

Ensemble	Rôle	Analogie
Entraînement (<i>train</i>)	Optimiser les paramètres θ	Les exercices qu'on travaille
Validation	Choisir les réglages (hyperparamètres), détecter le surapprentissage	Les examens blancs
Test	Mesure finale, utilisée une seule fois	L'examen final

Exemple de découpage : **80 % / 10 % / 10 %**.

Règle d'or: ne jamais entrainer le modèle sur les données de test, sinon le score est truqué.

Supervisé vs non supervisé

	Supervisé	Non supervisé
Données	Entrées x avec la réponse y (labels)	Entrées x sans label
Objectif	Prédire y à partir de x	Découvrir une structure dans les données
Exemples	Détection de spam, traduction, analyse de sentiment	Clustering, Word2Vec

Les labels demandent souvent du **travail humain** (annotation) qui est très coûteux. Les algorithmes non supervisé fonctionnent sans label, mais ne sont pas adaptés pour toutes les tâches.

Exemple supervisé : détecter les spams

Tâche : dire si un email est un spam.

1. **Données** : 5 000 emails
2. **Labels** : chaque email est annoté **spam** ($y = 1$) ou **non-spam** ($y = 0$)
3. **Fonction** : $f(x = \text{email}) = y = \text{label}$

Email	Label
« Gagnez 1000 € maintenant, cliquez ici ! »	spam
« Réunion de projet demain à 10h »	non-spam

Spam : représenter l'email par des nombres

Un ordinateur ne calcule que sur des **nombres**. On compte les mots (comme dans la partie 2) :

x = vecteur des **occurrences de chaque mot** du vocabulaire

vocabulaire :	gagnez	cliquez	réunion	demain	...	
email 1 :	1	1	0	0	...	(spam)
email 2 :	0	0	1	1	...	(non-spam)

$$\hat{y} = \sigma(w \cdot x + b) \in [0, 1]$$

- w : un **poids par mot** (« gagnez » → *poids élevé* : signal de spam)
- σ : transforme le score en **probabilité** d'être un spam
- **Paramètres** $\theta = (w, b)$: avec un vocabulaire de 10 000 mots, **10 001 paramètres** à optimiser (contre des milliards pour un LLM)

La fonction de perte (Loss)

On mesure l'erreur du modèle avec une **fonction de perte** $\mathcal{L}$.

Pour une classification binaire (ex. spam / pas spam) :

$$\mathcal{L} = - \left[y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y}) \right]$$

C'est la **cross-entropy**. Plus $\mathcal{L}$ est faible, mieux le modèle prédit.

Un email est un spam ($y = 1$) :

- le modèle dit $\hat{y} = 0,9 \rightarrow \mathcal{L} \approx 0,11$ (petite erreur)
- le modèle dit $\hat{y} = 0,1 \rightarrow \mathcal{L} \approx 2,30$ (grosse erreur)

Objectif : trouver θ^* tel que $\mathcal{L}$ soit minimale sur les données d'entraînement.

Discussion : comment trouver le minimum (s'il existe) de la fonction de perte ?

Descente de gradient

Entraîner le filtre à spam = trouver les θ qui minimisent la perte sur les **80 % de données d'entraînement**.

Pour les réseaux de neurones, la fonction de perte est très complexe, non linéaire et multidimensionnelle : impossible de résoudre directement "dérivée = 0".

Idée : se déplacer dans la direction qui **réduit** la fonction de perte.

$$\theta \leftarrow \theta - \alpha \cdot \frac{\partial \mathcal{L}}{\partial \theta}$$

- α = **learning rate** (taux d'apprentissage), un hyperparamètre crucial
- $\frac{\partial \mathcal{L}}{\partial \theta}$ = gradient = direction de la pente ascendante
- on se déplace à chaque étape de l'apprentissage en direction - $\frac{\partial \mathcal{L}}{\partial \theta} x \alpha$

Analogie : vous êtes dans le brouillard sur une montagne. Vous voulez descendre dans la vallée. À chaque pas, vous regardez la pente sous vos pieds et avancez dans la direction la plus raide vers le **bas**.

Rétropropagation (Backpropagation)

Dans un réseau de neurones, le gradient se calcule par **rétropropagation** :

Forward pass :

$x \rightarrow [\text{Couche 1}] \rightarrow [\text{Couche 2}] \rightarrow [\text{Couche 3}] \rightarrow \hat{y} \rightarrow L$

Backward pass (règle de la chaîne) :

$\partial L / \partial \theta_1 \leftarrow \partial L / \partial \theta_2 \leftarrow \partial L / \partial \theta_3 \leftarrow \partial L / \partial \hat{y}$

La **règle de la chaîne** permet de calculer les gradients couche par couche, de la sortie vers l'entrée.

PyTorch / TensorFlow font ça automatiquement (**autograd**).

Surapprentissage (Overfitting)

Le modèle **mémorise** les données d'entraînement au lieu d'en apprendre les patterns.

On le détecte en comparant les scores sur l'**entraînement** et sur la **validation / le test**.

	Accuracy train	Accuracy test
Bon modèle	92%	89%
Overfitting	99%	62%

Solutions courantes :

- **Dropout** : désactiver des neurones aléatoirement pendant l'entraînement
- **Weight decay** : pénaliser les poids trop grands (L_2 régularisation)
- **Early stopping** : arrêter quand la validation stagne
- **Plus de données** : (et des données plus diverses et représentatives), le remède le plus efficace

Spam : évaluer sur les données de test

Après l'entraînement (descente de gradient sur les 80 % d'entraînement), on **évalue sur les 10 % de test**, jamais vus par le modèle :

- **Accuracy** : part des emails correctement classés
- **Précision / rappel** : combien de vrais spams détectés, combien de fausses alertes
- Un bon filtre à spam n'est pas celui qui connaît ses 4 000 emails d'entraînement, mais celui qui classe correctement **les emails de demain**.

Exemple non supervisé : découvrir des groupes

Pas de labels : on donne seulement les données, la machine **cherche une structure**.

- **Clustering** : regrouper des articles de presse par thème (sport, politique, culture...) **sans** avoir dit quels thèmes existent
- **Word2Vec** : apprendre à représenter les mots par des vecteurs en observant quels mots apparaissent ensemble → **prochaine partie**

Le non supervisé est à la base des **LLMs** : ils apprennent à partir de quantités énormes de texte **sans annotation manuelle** (séance 2).

Quiz 2

Un modèle atteint **99% d'accuracy** sur les données d'entraînement et **62%** sur les données de test.

Que se passe-t-il ?

- **A)** Le modèle est parfait, 99% c'est excellent
- **B)** Il y a du surapprentissage (*overfitting*)
- **C)** Les données de test sont mauvaises
- **D)** Le learning rate est trop élevé

Séance 2 : 29 octobre

Représentations vectorielles du texte : comment traduire des mots en vecteurs ?

Vecteurs de mots · Bag-of-Words · Word2Vec ·

Architectures traitement du texte · RNNs · Transformers

Lectures conseillées :

Vaswani et al. (2017), "Attention is All You Need" : abstract + intro

`celia.nouri@inria.fr`