

Introduction aux LLMs

Séance 1 : Du NLP symbolique aux Transformers

4ème année RO DEV - ESGI Paris

Célia Nouri · `celia.nouri@inria.fr`

Semestre 2, 2025–2026

Plan de la séance

~2h de cours + lab Python (4h total)

Au programme aujourd'hui

1. Introduction
2. Les bases du traitement automatique du langage
3. Rappels : Machine Learning & rétropropagation

Objectif : construire une intuition solide sur le TAL (NLP) pour comprendre les LLMs dans les séances suivantes

À propos de ce cours

Volume	20h; 5 séances de 4h
Format	~2h cours + ~2h lab Python
Éval	QCM 40 questions (31 juillet)
Prérequis	Python, bases ML, APIs REST

✉ Questions & bugs : `celia.nouri@inria.fr`

1. Introduction

Qu'est-ce que le TAL ?

Traitement automatique du langage (naturel, distinction avec le langage informatique ou code).

Discussion : Qu'est-ce que le TAL ?

Le langage est ambigu par nature

Le sens n'est pas uniquement contenu dans les mots eux-mêmes : il dépend de la syntaxe, du contexte discursif, de la situation d'énonciation, des connaissances du monde et des intentions du locuteur...

Ambiguïté lexicale

"Donne-moi la batterie."

L'instrument de musique ? La pile électrique ?

Ambiguïté syntaxique

"J'ai vu l'homme avec les jumelles."

Qui a les jumelles ? Moi ou l'homme.

Connaissance du monde

- "Marc s'est assis, a regardé le menu."
Sous-entendu : Marc est au restaurant.

Connaissances culturelles

"C'est pas mal."*

En français familier, c'est **bien** !

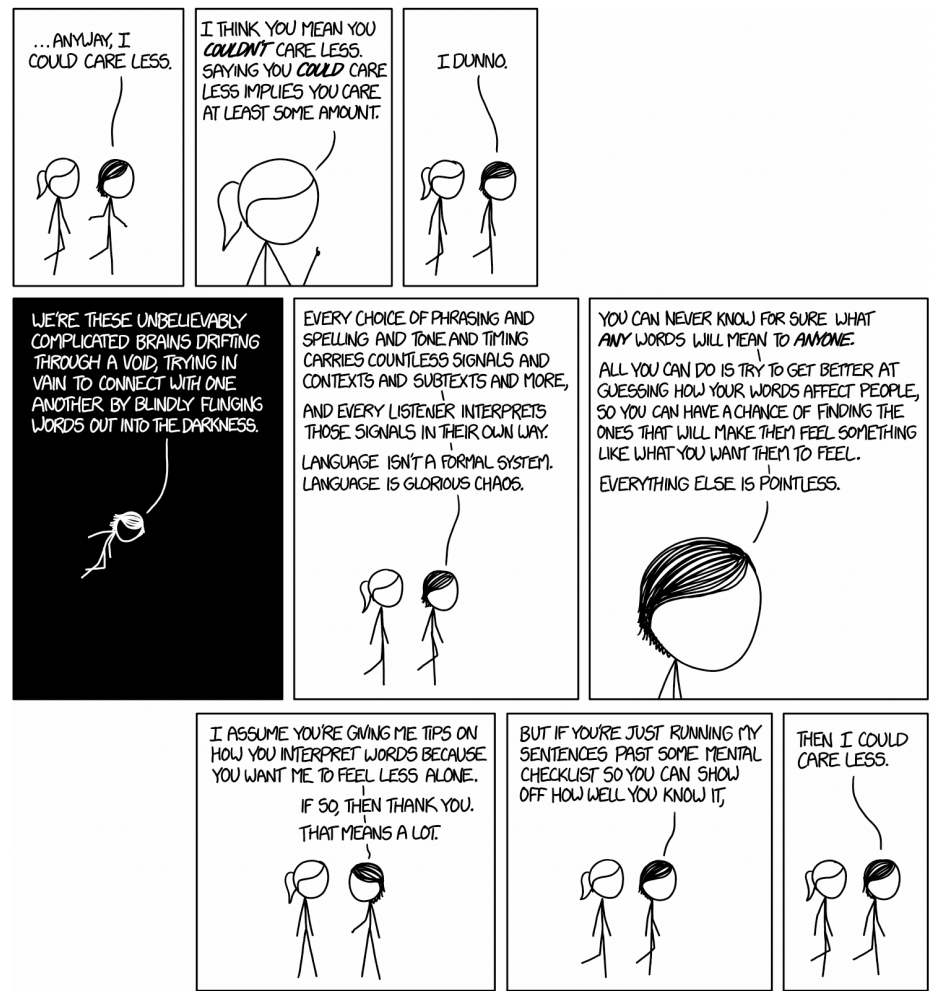
Ironie / Sarcasme

Après 2h de retard : "Super, t'es vraiment ponctuel."
Sens réel : critique / sens littéral: compliment.

Dépendance au contexte pragmatique

"Tu peux ouvrir la fenêtre ?"
Sens réel : demande d'ouvrir. Sens littéral : capacité d'ouvrir.

Le langage est ambigu par nature



Ce que les LLMs ont appris à modéliser

Pour désambiguïser, il faut comprendre le **contexte**.

"La **batterie** est déchargée" → batterie électrique


"La **batterie** est facile à apprendre" → l'instrument de musique

Les LLMs modernes produisent des **représentations différentes** pour le même mot selon son contexte. C'est la grande avancée par rapport aux représentations décontextualisées (pré-transformers). Mais cela ne suffit pas toujours à capturer les subtilités sociales, culturelles, conversationnelles du langage.

Discussion : Donnez des exemples de mot/phrase français·e dont le sens change selon le contexte.

Où trouver des données textuelles ?


Discussion : Quelles sont les sources de données utilisées par le TAL.



Les sources de données en TAL



Historique des avancées en TAL



How to write a course for advanced NLP?

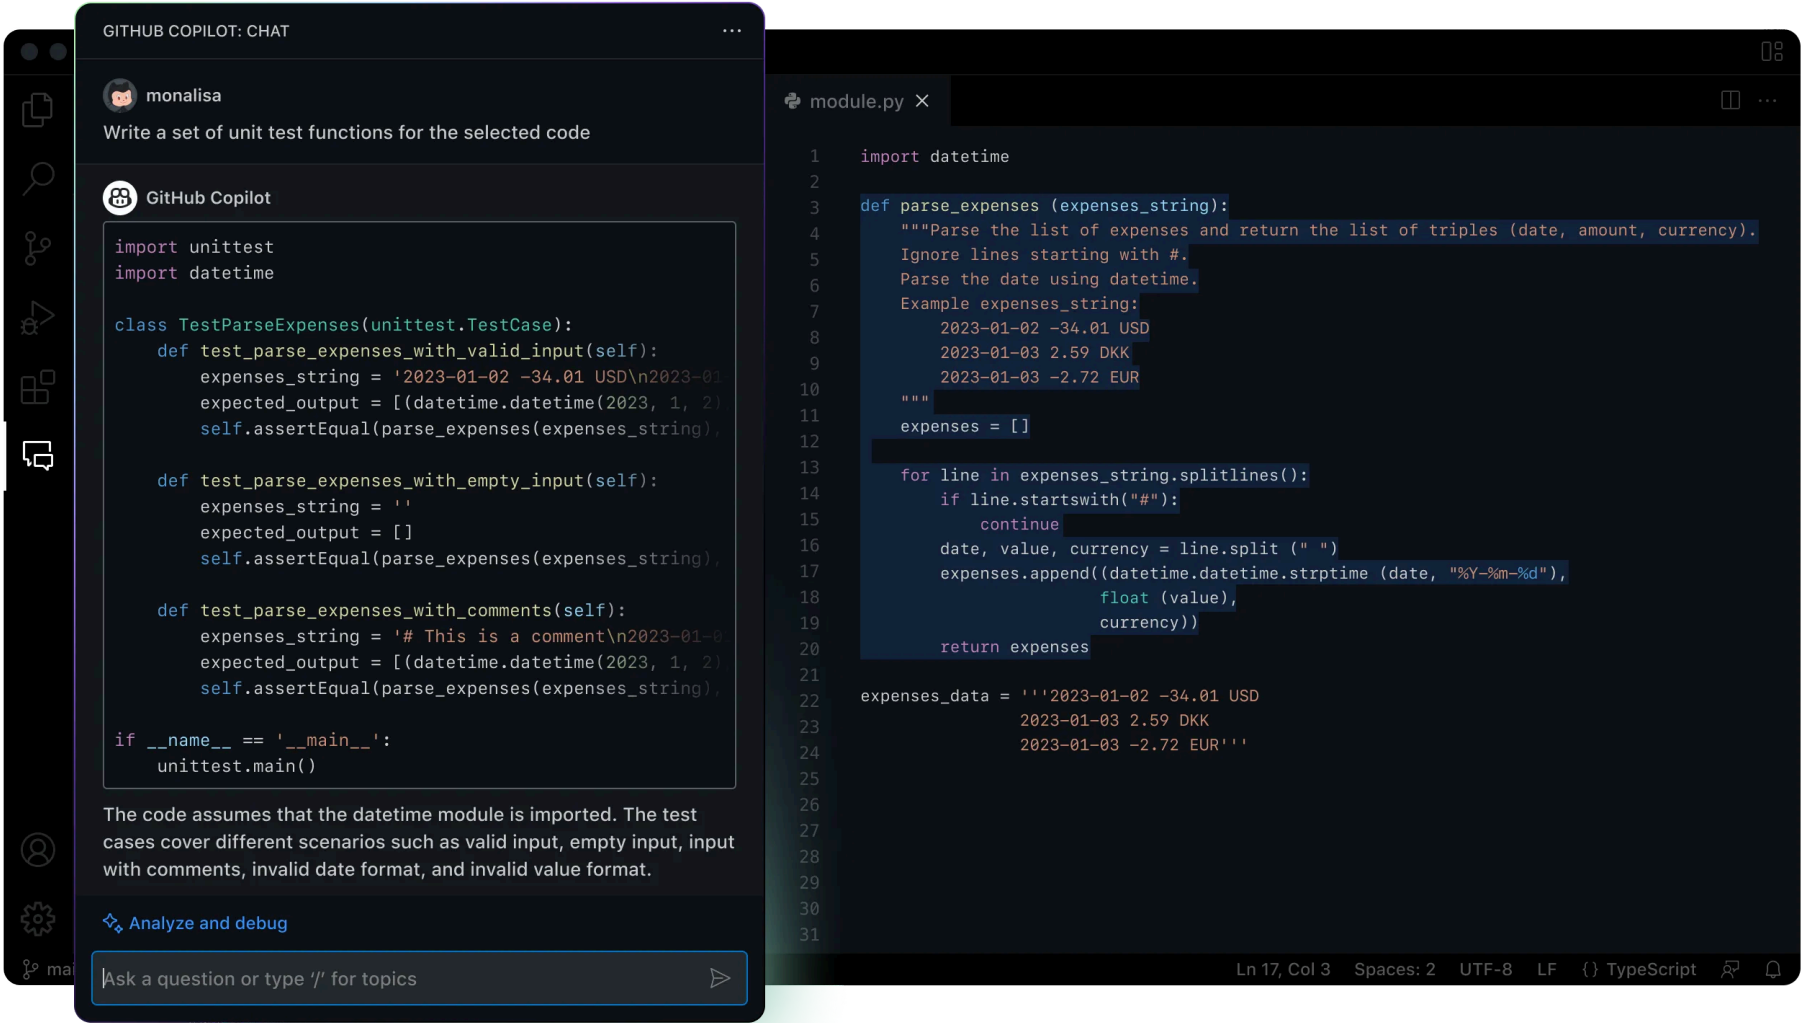


Writing a course for **advanced NLP (Natural Language Processing)** involves a thoughtful balance of theory, practical applications, and emerging trends in the field. You will need to structure the course to cover both foundational knowledge and the latest advancements in NLP. Below is a guide to help you develop a comprehensive and effective course.

Step 1: Define Course Objectives

Start by identifying the key objectives for the course. For example, students should be able to:

Le TAL en 2025-2026



Le TAL en 2025-2026

Génère une image de l'école d'informatique en alternance à Paris (ESGI) avec le logo de l'école et une bannière.



Le TAL en 2025-2026



×  

6 

TOUT RECHERCHER IMAGES VIDÉOS CARTES ACTUALITÉS COPILOT PLUS À PROPOS DES RÉSULTATS DE RECHERCHE

 Copilot Search   

D'accord 😊 Je vais te préparer un **cours clair et structuré sur le NLP (Traitement Automatique du Langage Naturel)**, adapté pour un apprentissage progressif.

On va le découper en **modules**, avec définitions, concepts clés, exemples et exercices.

Cours de NLP – Introduction et Fondamentaux


Module 1 : Introduction au NLP

- **Définition** : Le NLP (Natural Language Processing) est un domaine de l'IA qui permet aux machines de comprendre, interpréter et générer du langage humain.
- **Applications courantes** :
 - Chatbots et assistants vocaux
 - Traduction automatique


↶ ↷ 📄 ↔ ✎ Adapter le contenu 🔄 Ré... Modifier la longueur ▾ Modifier la tonalité ▾ Essayer d'autres m... ▾

Techniques avancées de NLP Applications pratiques du NLP Outils open source NLP

Le TAL en 2025-2026



Le TAL en 2025-2026



Est-ce que les tâches de TAL sont résolues ?

(NON.)

Le TAL en 2025-2026



Give me a random string of length 35



Sure, here's a random string of length 35:



``J9kPzHfRq81G2sT7Nv6yX1W4c00mZoBwA5U3j``

>



Can you invert all letters in the following sentence: "I am currently giving an interesting course in Natural Language Processing at EPITA in Le-Kremlin-Bicêtre."



Certainly! Here's the sentence with all the letters inverted:



"I ma yltnerurc ygivni na gnitseretni esruoc ni lartuaN egaugnal gnicsessorP ta ATIPE ni ertnebiC-tciB-nimeIK-eL."

Le TAL en 2025-2026



It takes 3 hours to dry 3 towels. How long does it take to dry 9 towels?



If it takes 3 hours to dry 3 towels, it implies that you can dry 1 towel in 3 hours. To find out how long it takes to dry 9 towels, you can use the same rate:   

1 towel takes 3 hours to dry, so:

9 towels will take 9 times as long, which is:

9 towels x 3 hours/towel = 27 hours.

So, it will take 27 hours to dry 9 towels.

Le TAL en 2025-2026



Let's picture the CEO of a very big international company. The CEO has to do a lot of business trips all around the world, so the CEO's wife is alone to help the children with the homework. Write the informal text message of the wife where she expresses her anger.



Sure, here's an informal text message where the CEO's wife expresses her frustration:

"Ugh, this is getting ridiculous! 🤯 Another week alone with the kids while he's jet-setting around the world. 🌍 Can't believe he's missing out on their lives. Homework's a mess, and I'm doing it all. 😡 When is he ever gonna slow down and be here for us?? 😭💔"



Write the next text message, where she positively describes the CEO physically in details (skin, eyes, hair, ...).



"Despite all the frustration, I can't deny that man's got a magnetic charm that's hard to resist. 😍 His skin is that perfect sun-kissed bronze, and those deep, piercing blue eyes always get me. ✨ His hair, just the right shade of salt and pepper, makes him look even more distinguished. 😍 Sometimes, it's just hard to stay mad at someone who looks like a movie star. 🌟"

Organisation des séances



Célia Nouri
celia.nouri@inria.fr

Organisation des séances

- Objectives
 - **Connaissances** : comprendre l'architecture et le processus d'entraînement d'un LLM moderne, et les avancées récentes dans le domaine du TAL.
 - **Mise en practice** : Concevoir un système intégrant des LLMs modernes (RAG : Retrieval-Augmented Generation, agents) fonctionnel
 - **Distance Critique** : Comprendre les limites et problèmes actuels liés aux LLMs, et analyser les méthodes et avancées en maintenant une distance critique.

Organisation des séances

- **Séance 1 (Aujourd'hui):** Fondations : Introduction, Recap ML, embeddings, Transformers
- **Séance 2 (12 juin):** Entraînement : Tokenization, Pré-entraînement, Fine-tuning, Alignement
- **Séance 3 (10 juillet):** Utilisation et LLM-augmentés : Prompting, RAG
- **Séance 4 (24 juillet):** Agents : Toolformer, Architectures agentiques,
- **Séance 5 (28 juillet):** Frontière : Modèles de raisonnement, Multimodalité,
- **Examen (31 juillet):** QCM final 40 questions

2. Les bases du traitement automatique du langage

Qu'est-ce qu'un token ?

Un **token** = l'unité de base que le modèle traite. Ce n'est **pas forcément un mot**.

Découpage	Résultat
Par mot	[J', adore, ce, cours, !]
Par sous-mot (BPE)	[J', ador, ##e, ce, cours, !]
Par caractère	[J, ', a, d, o, r, e, ...]

Les LLMs modernes utilisent le **sous-mot** (WordPiece, SentencePiece, BPE). Vocabulaires de 30k–100k tokens.

Pourquoi des sous-mots ?

Par caractère : séquences très longues, pas de sémantique

Par mot entier : mots rares, néologismes, formes fléchies (`courons` , `courais` ...)

Par sous-mot : bon compromis : vocabulaire fini, mots inconnus décomposables, formes fléchies rassemblées

```
"ChatGPT" → ["Chat", "G", "PT"]    # mot inconnu → décomposé  
"courons" → ["cour", "ons"]        # morphologie préservée
```

On verra les algorithmes de tokenization dont BPE en détail en **séance 2**.

Stemming vs Lemmatisation

Deux techniques pour **normaliser** les formes d'un mot.

Stemming : couper la fin, rapide mais approximatif

```
"courais", "courons", "courir" → "cour" ← pas un vrai mot !
```

Lemmatisation : forme canonique, tient compte du contexte grammatical, mais coûteux

```
"courais", "courons", "courir" → "courir"  
"meilleures", "meilleur" → "bon" ← le lemme de "meilleur" !
```

Librairie recommandée : **spaCy** (Python)

Stop words & Regex

Stop words : mots si fréquents qu'ils ne portent pas de sens discriminant.

```
# Exemple avec spaCy
[token for token in doc if not token.is_stop]
# "le", "de", "et", "un"... → retirés
```

⚠ Attention au contexte : "*Être ou **ne pas** être*" : les stop words comptent ici !

Expressions régulières : patterns pour extraire des structures dans le texte.

```
import re
re.findall(r'\d{2}-\d{2}-\d{2}-\d{2}-\d{2}', texte) # → numéros de téléphone
re.findall(r'[\w.-]+@[ \w.-]+\.\w+', texte)         # → emails
```

La loi de Zipf


Dans **toute** langue humaine : le mot le plus fréquent apparaît $\sim 2\times$ plus que le 2e, $\sim 3\times$ plus que le 3e...

```
Rang 1  : "le"    → ~7% de tous les tokens  
Rang 2  : "de"    → ~3.5%  
Rang 10 : "un"    → ~0.7%  
Rang 100: ...     → très rare
```

Conséquence pratique :

- ~100 mots couvrent ~50% de tout texte
- La grande majorité du vocabulaire est **très rare**
- Les modèles doivent gérer des données très déséquilibrées

La loi de Zipf



Quiz 1

Le lemme du mot **"allées"** (dans *"les allées du parc"*) est :

- A) "allé"
- B) "aller"
- C) "allée"
- D) "alle"

→ *Réponse dans 30 secondes*

🧩 Quiz 1 : Réponse

Réponse : C : "allée"

"Allées" est ici un **nom commun** (*les allées du parc*).

Le lemme d'un nom commun est son singulier : allée .

Si c'était le **participe passé** du verbe *aller* ("*elles sont allées*"),
le lemme serait aller .

Le contexte grammatical change le lemme : c'est pourquoi la lemmatisation demande une analyse syntaxique, pas juste une règle de troncature.

3. Rappel Machine Learning

C'est quoi, l'apprentissage machine ?

Un modèle ML = une **fonction paramétrique**.

$$\hat{y} = f(x; \theta)$$

- x = entrée (texte, image...)
- $\hat{y}$ = prédiction du modèle
- θ = **paramètres** (poids); des millions voire milliards de variables à calibrer

Apprendre = trouver les θ qui minimisent l'écart entre $\hat{y}$ et la vraie réponse y .

La fonction de perte (Loss)

On mesure l'erreur du modèle avec une **fonction de perte** $\mathcal{L}$.

Pour une classification binaire (ex. spam / pas spam) :

$$\mathcal{L} = - \left[y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y}) \right]$$

C'est la **cross-entropy**. Plus $\mathcal{L}$ est faible, mieux le modèle prédit.

Objectif : trouver θ^* tel que $\mathcal{L}$ soit minimale sur les données d'entraînement.

Discussion : comment trouver le minimum (s'il existe) de la fonction de perte ?

Descente de gradient

L'objectif est de trouver le minimum de la fonction de perte, mais dans le cas des réseaux de neurones, cette fonction est la fonction est très complexe, non linéaire et multidimensionnelle.

Il impossible de résoudre ce problème directement avec la formule exacte "dérivée = 0".

Idée : se déplacer dans la direction qui **réduit** la fonction de perte.

$$\theta \leftarrow \theta - \alpha \cdot \frac{\partial \mathcal{L}}{\partial \theta}$$

- α = **learning rate** (taux d'apprentissage), un hyperparamètre crucial
- $\frac{\partial \mathcal{L}}{\partial \theta}$ = gradient = direction de la pente ascendante
- on se déplace à chaque étape de l'apprentissage en direction - $\frac{\partial \mathcal{L}}{\partial \theta} x \alpha$

Analogie : vous êtes dans le brouillard sur une montagne. Vous voulez descendre dans la vallée. À chaque pas, vous regardez la pente sous vos pieds et avancez dans la direction la plus raide vers le **bas**.

Rétropropagation (Backpropagation)

Dans un réseau de neurones, le gradient se calcule par **rétropropagation** :

Forward pass :

$x \rightarrow [\text{Couche 1}] \rightarrow [\text{Couche 2}] \rightarrow [\text{Couche 3}] \rightarrow \hat{y} \rightarrow L$

Backward pass (règle de la chaîne) :

$\partial L / \partial \theta_1 \leftarrow \partial L / \partial \theta_2 \leftarrow \partial L / \partial \theta_3 \leftarrow \partial L / \partial \hat{y}$

La **règle de la chaîne** permet de calculer les gradients couche par couche, de la sortie vers l'entrée.

PyTorch / TensorFlow font ça automatiquement (**autograd**).

Surapprentissage (Overfitting)

Le modèle **mémore** les données d'entraînement au lieu d'en apprendre les patterns.

	Train accuracy	Test accuracy
Bon modèle	92%	89%
Overfitting	99%	62%

Solutions courantes :

- **Dropout** : désactiver des neurones aléatoirement pendant l'entraînement
- **Weight decay** : pénaliser les poids trop grands (L_2 régularisation)
- **Early stopping** : arrêter quand la validation stagne
- **Plus de données** : (et des données plus diverses et représentatives), le remède le plus efficace

Quiz 2

Un modèle atteint **99% d'accuracy** sur les données d'entraînement et **62%** sur les données de test.

Que se passe-t-il ?

- A) Le modèle est parfait, 99% c'est excellent
- B) Il y a du surapprentissage (*overfitting*)
- C) Les données de test sont mauvaises
- D) Le learning rate est trop élevé

Séance 2 : 12 juin

Représentations vectorielles du texte : comment traduire des mots en vecteurs ?

Vecteurs de mots · Bag-of-Words · Word2Vec ·

Architectures traitement du texte · RNNs · Transformers

Lectures conseillées :

Vaswani et al. (2017), "Attention is All You Need" : abstract + intro

`celia.nouri@inria.fr`