

Introduction aux LLMs

Séance 3 : Entraînement LLM

4ème année RO DEV - ESGI Paris

Célia Nouri · `celia.nouri@inria.fr`

Semestre 2, 2025–2026

Agenda

1. Tokenization
2. Pré-entraînement à grande échelle
3. Lois de Chinchilla
4. Instruction tuning
5. Alignement : RLHF et DPO
6. Évaluation

1. Tokenization

Rappel : pourquoi tokeniser ?

Un LLM ne lit pas du texte — il lit une **séquence d'entiers**.

```
"ChatGPT est utile"  
  ↓ tokenizer  
[14526, 38, 920, 374, 5505]  
  ↓ embeddings  
[v1, v2, v3, v4, v5] ← vecteurs denses
```

Le tokenizer est donc la **porte d'entrée** du modèle. Son vocabulaire et ses décisions de découpage ont un impact direct sur :

- les performances du modèle
- le coût d'inférence (plus de tokens = plus cher)
- les langues bien ou mal traitées

Trois stratégies naïves

Stratégie	Exemple	Problème
Par mot	["chat", "chats"] → IDs différents	Mots rares, formes fléchies, OOV
Par caractère	["c", "h", "a", "t"]	Séquences très longues, peu de sémantique
Par sous-mot	["chat", "##s"]	✅ Bon compromis

Les LLMs modernes utilisent tous une approche **sous-mot** apprise depuis les données. Les trois algorithmes principaux : **BPE**, **WordPiece**, **Unigram**.

BPE — Byte-Pair Encoding

Sennrich et al., 2016 — algorithme le plus répandu (GPT, LLaMA, Mistral...).

Entraînement :

1. Partir du vocabulaire de caractères (ou bytes)
2. Compter toutes les paires adjacentes dans le corpus
3. Fusionner la paire la plus fréquente → nouveau token
4. Répéter jusqu'à atteindre la taille de vocabulaire cible

On obtient une liste ordonnée de **règles de fusion** (*merge rules*).

Inférence : appliquer les règles dans l'ordre appris.

BPE — Exemple pas à pas

Corpus : "low low low lowest newest"

Vocabulaire initial : l o w e s t n </w>

```
Étape 1 – paires fréquentes : (l,o)×4 (o,w)×5 (w,</w>)×3 ...  
→ fusionner (o,w) → ow  
new vocab : l ow e s t n </w>
```

```
Étape 2 – (l,ow)×4 ... → fusionner (l,ow) → low  
new vocab : low e s t n </w>
```

```
Étape 3 – (low,</w>)×3 → fusionner → low</w>  
...
```

À l'inférence : "lowest" → ["low", "e", "st"] en appliquant les règles dans l'ordre.

Byte-level BPE

Variante utilisée par **GPT-2, GPT-3, GPT-4, RoBERTa, LLaMA** :

- Vocabulaire de base = **256 bytes** (couvre tout l'Unicode)
- **Jamais de token inconnu** : n'importe quel texte, dans n'importe quelle langue ou encodage, est représentable
- Les fusions se font sur des séquences d'octets, pas de caractères

```
# GPT-4 tokenizer (tiktoken)
"ChatGPT" → ["Chat", "G", "PT"]      # mot inconnu → décomposé en bytes connus
"你好"    → ["你", "好"]              # chinois géré nativement
"🤖"      → ["<0xF0>", "<0x9F>", "<0xA4>", "<0x96>"] # emoji → bytes bruts
```


WordPiece

Algorithme utilisé par **BERT, DistilBERT, ELECTRA**.

Différence avec BPE : au lieu de fusionner la paire *la plus fréquente*, on fusionne celle qui **maximise la vraisemblance** du corpus :

$$\text{score}(A, B) = \frac{P(AB)}{P(A) \cdot P(B)}$$

On fusionne A et B si les voir ensemble est plus probable que les voir séparément.

Notation : les sous-mots de continuation sont préfixés par `##`

```
"playing" → ["play", "##ing"]  
"tokenize" → ["token", "##ize"]
```

Unigram Language Model

Algorithme utilisé par T5, ALBERT, mBART (via SentencePiece).

Logique inverse de BPE :

1. Partir d'un très grand vocabulaire (sur-ensemble)
2. Calculer la probabilité de chaque token dans un modèle unigramme
3. Supprimer les tokens dont la suppression augmente le moins la perte
4. Répéter jusqu'à atteindre la taille cible

Segmentation : à l'inférence, on cherche le découpage qui **maximise la probabilité** $\prod_i P(t_i) \rightarrow$ algorithme de Viterbi.

Permet plusieurs découpages possibles : utile pour la **data augmentation** à l'entraînement.

SentencePiece

Bibliothèque de **Kudo & Richardson (2018, Google)** qui implémente BPE *et* Unigram.

Innovation clé : fonctionne directement sur le texte brut, **sans pré-tokenisation par espace**.

```
Word-level tokenizer : "New York" → ["New", "York"]  
SentencePiece       : "New York" → ["_New", "_York"]  
                      (_ = espace encodé comme caractère)
```

Avantages :

- Universel : pas d'hypothèse sur les espaces (chinois, japonais, thaï...)
- Déterministe et réversible : on peut toujours retrouver le texte original
- Utilisé par **LLaMA 1/2, Mistral, Gemma, T5**

Comparatif des tokenizers

Modèle	Tokenizer	Taille vocab
GPT-2 / GPT-3	Byte-level BPE	50 257
GPT-4 / Claude	Byte-level BPE (tiktoken)	~100 000
BERT	WordPiece	30 522
LLaMA 1/2	SentencePiece (BPE)	32 000
LLaMA 3	tiktoken (BPE)	128 256
T5 / FLAN	SentencePiece (Unigram)	32 100
Mistral	SentencePiece (BPE)	32 000

Les grands vocabulaires (LLaMA 3, GPT-4) améliorent la couverture multilingue et réduisent le nombre de tokens par phrase.

Effets pratiques de la tokenization

Biais multilingue : un token en anglais $\approx$ 1 mot ; en arabe ou en thaï $\approx$ 3–5 tokens pour la même information $\rightarrow$ coût plus élevé, fenêtre de contexte plus vite remplie.

Tokens spéciaux : chaque modèle définit ses propres marqueurs.

```
[BOS] [EOS] [PAD] [UNK]      ← BERT / LLaMA  
<endoftext> <im_start>      ← GPT / ChatML  
<s> </s> [INST] [/INST]     ← LLaMA 2 chat
```

Le tokenizer fait partie du modèle : changer de tokenizer = réentraîner depuis zéro.

Quiz — Tokenization

1. Quelle est la différence entre BPE et WordPiece ?
2. Pourquoi le *byte-level* BPE ne produit-il jamais de token `[UNK]` ?
3. Vrai / Faux : SentencePiece nécessite de séparer les mots par des espaces avant de tokeniser.
4. Un modèle avec un vocabulaire de 128k tokens traite-t-il les textes multilingues mieux ou moins bien qu'un modèle avec 32k tokens ? Pourquoi ?

🧩 Quiz — Réponses


1. BPE fusionne la paire *la plus fréquente* ; WordPiece fusionne celle qui maximise la vraisemblance $P(AB)/(P(A) \cdot P(B))$.
2. Le vocabulaire de base contient les 256 bytes possibles → tout octet est représentable, donc tout texte est encodable sans token inconnu.
3. **Faux.** SentencePiece encode l'espace comme un caractère `▯`, ce qui lui permet de fonctionner sur du texte brut sans pré-tokenisation.
4. Mieux — un grand vocabulaire alloue plus de tokens aux langues non-latines, réduisant le nombre de tokens par phrase et améliorant la représentation.

2. Pré-entraînement à grande échelle

La logique des LLMs modernes

Étape 1 — Pré-entraînement : tâche non supervisée, immense corpus

Étape 2 — Fine-tuning / Alignement : adaptation au comportement souhaité



Pourquoi cette séparation ? Le pré-entraînement est coûteux mais ne se fait qu'une fois. Tout le reste (sections 4, 5, 6) part de ce modèle de base.

Pré-entraînement : prédire le prochain token

Pour un modèle décodeur (type GPT), la tâche est :

Étant donné tous les tokens précédents, prédire le suivant.

```
Input  : "Le chat est assis sur le"  
Cible  : "tapis"
```

- Aucune annotation humaine nécessaire — tout texte est une donnée gratuite
- GPT-3 : ~300 milliards de tokens d'entraînement
- LLaMA 3 : ~15 000 milliards de tokens

Ce que le modèle apprend implicitement

En apprenant à prédire la suite, le modèle doit **modéliser** :

- La **grammaire** (pour prédire la bonne forme)
- Les **faits du monde** (Paris est la capitale de la France)
- Le **raisonnement** (si A alors B)
- Le **style et le ton**
- Les **relations entre concepts**

"Les LLMs ne savent pas ce qu'ils savent. Ils savent ce qui est probable."

D'où viennent les données ?

Corpus	Contenu	Taille approx.
Common Crawl	Archive brute du web, depuis 2008	plusieurs Po
C4 (Google)	Common Crawl filtré et nettoyé	~750 Go
The Pile (EleutherAI, 2020)	22 sous-corpus : livres, code, PubMed, ArXiv...	825 Go
FineWeb (Hugging Face, 2024)	Common Crawl filtré, déduplication poussée	15 000 Md tokens
Wikipedia, livres, code (GitHub)	Sources denses en connaissance / structure	variable

En pratique, un LLM récent mélange **web généraliste + code + livres + données multilingues**, avec des proportions choisies à la main (*data mixture*).

Nettoyer les données : pas si simple

Le web brut est plein de **doublons, spam, texte de mauvaise qualité, contenus toxiques**.

Pipeline typique de nettoyage :

```
Filtrage de langue → Déduplication → Filtrage qualité (heuristiques + classifieur)  
→ Suppression PII → Filtrage contenu toxique/NSFW → Mélange des sources
```

Deux risques concrets :

- **Contamination** : si des benchmarks d'évaluation fuient dans les données d'entraînement, le modèle les "a déjà vus" → scores gonflés (section 6)
- **Droit d'auteur** : procès *New York Times vs OpenAI* (2023) — utiliser des textes protégés pour l'entraînement est-il légal ? Question encore non tranchée juridiquement.

L'infrastructure : entraîner à l'échelle

Un modèle comme GPT-4 ou LLaMA 3 ne tient pas sur un seul GPU — il faut **paralléliser** :

Type de parallélisme	Principe
Data parallelism	Même modèle, batches différents sur chaque GPU
Tensor parallelism	Une même couche est découpée entre plusieurs GPU
Pipeline parallelism	Les couches du modèle sont réparties sur différents GPU

Ordres de grandeur : **des milliers de GPU**, plusieurs **mois** d'entraînement, coûts estimés à **plusieurs dizaines de millions de dollars** pour les plus gros modèles.

Question naturelle : avec un budget de calcul fixé, comment répartir entre **taille du modèle** et **quantité de données** ? → Lois de Chinchilla.

Quiz — Pré-entraînement

1. Pourquoi le pré-entraînement ne nécessite-t-il aucune annotation humaine ?
2. Citez un risque concret lié à des données d'entraînement mal nettoyées.
3. Quel type de parallélisme découpe une **même couche** du modèle entre plusieurs GPU ?

🧩 Quiz — Réponses

1. La cible (le token suivant) est déjà présente dans le texte lui-même — tout texte brut fournit ses propres paires (input, cible) gratuitement.
2. Contamination des benchmarks (scores gonflés artificiellement) ou violation de droits d'auteur (ex. procès NYT vs OpenAI).
3. Le **tensor parallelism**.

3. Lois de Chinchilla

Une question simple, mais coûteuse

Avec un budget de calcul **fixé** (un nombre de GPU pendant un temps donné), faut-il :

- Entraîner un **très grand modèle** sur **peu de données** ?
- Ou un **modèle plus petit** sur **beaucoup plus de données** ?

Se tromper coûte des millions de dollars de calcul gaspillé. Deux papiers y répondent.

Kaplan et al. (2020) — les premières lois d'échelle

"Scaling Laws for Neural Language Models", OpenAI.

Constat : la performance suit une loi de puissance prévisible selon la taille du modèle, la quantité de données et le calcul utilisé.

Conclusion (de l'époque) : à budget de calcul fixé, il vaut mieux **prioriser la taille du modèle** et ne pas trop se soucier de la quantité de données.

→ Cette recommandation a motivé des modèles comme **GPT-3 (175B)** ou **Gopher (280B)**.

Hoffmann et al. (2022) — Chinchilla

"Training Compute-Optimal Large Language Models", DeepMind.

Résultat surprenant : la méthodologie de Kaplan et al. sous-estimait l'importance des données. Pour un budget de calcul fixé, **taille du modèle et nombre de tokens doivent croître au même rythme.**

Règle empirique : environ **20 tokens d'entraînement par paramètre** pour un usage optimal du calcul.

Conclusion : la plupart des grands modèles de l'époque (dont Gopher) étaient **trop gros et sous-entraînés.**

La preuve par l'exemple

Modèle	Paramètres	Tokens d'entraînement	Performance
Gopher (DeepMind)	280 milliards	300 milliards	référence
Chinchilla (DeepMind)	70 milliards	1 400 milliards	> Gopher, à calcul égal

Chinchilla est **4× plus petit** que Gopher, entraîné sur **~4.7× plus de tokens**, pour un coût de calcul **identique** — et surpasse Gopher sur la quasi-totalité des benchmarks.

Conséquence directe : de nombreux modèles étaient en réalité **sous-entraînés**, pas trop petits.

Une nuance importante : le coût d'inférence

Les lois de Chinchilla optimisent le coût de **l'entraînement**. Mais un modèle déployé à grande échelle est **utilisé (inféré) des milliards de fois** après son entraînement.

LLaMA (Meta, 2023) a fait un choix différent : entraîner des modèles **plus petits que l'optimum Chinchilla**, mais sur **encore plus de tokens** que ce que Chinchilla recommanderait — pour réduire durablement le coût d'inférence, quitte à dépenser plus de calcul à l'entraînement.

"Compute-optimal" (moins cher à entraîner) $\neq$ "inference-optimal" (moins cher à faire tourner ensuite).

Quiz — Chinchilla

1. Quelle est la principale différence entre les conclusions de Kaplan et al. (2020) et Hoffmann et al. (2022) ?
2. Chinchilla (70B) surpasse Gopher (280B) à calcul d'entraînement égal. Pourquoi n'est-ce pas contre-intuitif une fois qu'on connaît la loi de Chinchilla ?
3. Pourquoi une entreprise pourrait-elle choisir d'entraîner un modèle **au-delà** de l'optimum Chinchilla ?

🧩 Quiz — Réponses

1. Kaplan et al. priorisaient la taille du modèle ; Hoffmann et al. montrent que taille du modèle et quantité de données doivent croître **ensemble** (~20 tokens/paramètre).
2. Gopher était sous-entraîné par rapport à sa taille (300B tokens pour 280B params, largement sous la règle des 20:1) ; Chinchilla respecte ce ratio et exploite mieux le même budget de calcul.
3. Pour réduire le **coût d'inférence** à long terme : un modèle plus petit et sur-entraîné coûte plus cher à produire mais beaucoup moins cher à faire tourner en production, à qualité égale.

4. Instruction tuning

Le problème du modèle brut

Un modèle juste pré-entraîné sait **continuer du texte**, pas **suivre des instructions**.

```
Prompt : "Explique-moi la photosynthèse."
```

```
Modèle pré-entraîné brut :
```

```
"Explique-moi la mitose cellulaire.
```

```
Explique-moi la respiration cellulaire.
```

```
Explique-moi..." ← continue le style d'une liste de questions
```

```
Modèle instruction-tuned :
```

```
"La photosynthèse est le processus par lequel les plantes..."
```

Le modèle de base imite la distribution du **web** — qui contient autant de questions que de réponses.

Supervised Fine-Tuning (SFT)

Principe : ré-entraîner (brièvement) le modèle sur des paires (**instruction, réponse souhaitée**), rédigées ou validées par des humains.

```
Instruction : "Résume ce texte en 3 phrases : [...]"  
Réponse    : "Le texte explique que... En résumé..."
```

- Même fonction de perte que le pré-entraînement (prédiction du prochain token)
- Mais calculée **uniquement sur les tokens de la réponse**, pas sur l'instruction
- Beaucoup moins de données que le pré-entraînement : quelques milliers à quelques millions d'exemples, contre des milliards de documents

D'où viennent ces datasets d'instructions ?

Dataset	Origine	Idée clé
FLAN (Google, 2021 - 2022)	Reformulation de tâches NLP existantes en instructions	Généralisation à des tâches jamais vues
Self-Instruct (Wang et al., 2022)	Un LLM génère lui-même de nouvelles instructions à partir d'exemples de départ	Réduit le besoin d'annotation humaine
Alpaca (Stanford, 2023)	52k instructions générées via Self-Instruct (avec GPT-3), utilisées pour fine-tuner LLaMA	Modèle instruction-tuned pour ~600\$ de coût API
Dolly / OpenAssistant	Instructions rédigées par des humains (employés, volontaires)	Données 100% humaines, ouvertes

Self-Instruct illustre une idée puissante : **utiliser un LLM pour générer les données qui entraînent le suivant.**

Quiz — Instruction tuning

1. Un modèle pré-entraîné brut répond mal à "*Explique-moi la photosynthèse*". Pourquoi ?
2. Sur quels tokens calcule-t-on la perte pendant le SFT : l'instruction, la réponse, ou les deux ?
3. Qu'est-ce que **Self-Instruct** propose de nouveau par rapport à FLAN ?

🧩 Quiz — Réponses

1. Il n'a appris qu'à **continuer du texte** de la même manière que sur le web ; rien ne le pousse à *répondre* plutôt qu'à *continuer la liste de questions*.
2. Uniquement sur les tokens de la **réponse** — l'instruction sert de contexte, pas de cible à prédire.
3. Générer les instructions d'entraînement **automatiquement via un LLM**, plutôt que de reformuler des datasets NLP existants — beaucoup moins coûteux en annotation humaine.

5. Alignement : RLHF et DPO

Pourquoi ne pas s'arrêter au SFT ?

Même après l'instruction tuning, un modèle peut être :

- **Peu utile** : réponses vagues, trop courtes ou trop longues
- **Non sûr** : contenu dangereux, biaisé, ou toxique
- **Mal calibré** sur les préférences humaines fines (ton, style, niveau de détail)

Objectif d'**alignement** (Anthropic, *HHH*) : un modèle **Helpful, Honest, Harmless**.

Le SFT apprend "un exemple correct parmi d'autres". L'alignement apprend **une préférence relative** : "cette réponse est meilleure que celle-là."

RLHF — Reinforcement Learning from Human Feedback

Ouyang et al. (2022, OpenAI) — pipeline utilisé pour InstructGPT, ancêtre direct de ChatGPT.

```
Étape 1 – SFT           : fine-tuning supervisé (déjà vu)
Étape 2 – Reward Model  : entraîner un modèle à noter des réponses
Étape 3 – RL (PPO)      : optimiser le LLM pour maximiser cette note
```

Étape 2 : le modèle de récompense

On ne demande **pas** à des humains de noter une réponse dans l'absolu (trop subjectif) — on leur demande de **comparer** deux réponses.

```
Prompt : "Explique la relativité restreinte."
```

```
Réponse A: [claire, correcte]
```

```
Réponse B: [confuse, un peu fausse]
```

```
Humain : A > B
```

Le **reward model** est entraîné sur des milliers de comparaisons de ce type, pour apprendre à **prédire un score de préférence** pour n'importe quelle réponse.

Étape 3 : optimiser avec RL (PPO)

Le LLM est ensuite ajusté pour **générer des réponses que le reward model note bien** — via l'algorithme **PPO** (Proximal Policy Optimization).

LLM génère une réponse → Reward Model la note → PPO ajuste les poids du LLM
pour augmenter la note future

Garde-fou essentiel : une pénalité **KL-divergence** empêche le modèle de trop s'éloigner du modèle SFT initial — sinon il apprend à "tricher" avec le reward model (*reward hacking*) au lieu de vraiment s'améliorer.

Les limites du RLHF

- **Pipeline complexe** : 3 modèles à entraîner et maintenir (SFT, reward model, politique RL)
- **RL instable** : sensible aux hyperparamètres, coûteux à faire converger
- **Reward hacking** : le modèle peut exploiter des failles du reward model plutôt que réellement s'améliorer
- Nécessite de **stocker et faire tourner** le reward model en plus du LLM pendant l'entraînement

→ Motive une simplification : peut-on aligner un modèle **sans** RL ni reward model séparé ?

DPO — Direct Preference Optimization

Rafailov et al. (2023) — *"Direct Preference Optimization: Your Language Model is Secretly a Reward Model"*

Idée clé : on peut montrer mathématiquement qu'un objectif RLHF (reward model + PPO) admet une solution optimale exprimable **directement** en fonction du modèle de langage lui-même.

Résultat : **pas besoin d'entraîner un reward model séparé, ni de faire du RL**. On optimise directement une perte de classification sur les paires (réponse préférée, réponse rejetée).

```
DPO : ajuster le LLM pour augmenter P(réponse préférée)  
et diminuer P(réponse rejetée) — directement, par descente de gradient
```

RLHF vs DPO

Modèles à entraîner	SFT + Reward Model + Policy RL	SFT + un seul modèle final
Algorithme	PPO (reinforcement learning)	Descente de gradient supervisée
Stabilité	Sensible, coûteux à régler	Plus simple, plus stable
Popularité (2023+)	Standard historique (InstructGPT)	Largement adopté (Zephyr, Mixtral-Instruct, LLaMA 3...)

DPO ne remplace pas la **collecte de préférences humaines** — seulement la façon d'optimiser le modèle à partir de ces préférences.

Quiz — RLHF & DPO

1. Pourquoi demande-t-on aux humains de **comparer** deux réponses plutôt que de noter une réponse seule ?
2. À quoi sert la pénalité KL-divergence pendant l'étape RL du RLHF ?
3. Quelle est la principale simplification qu'apporte DPO par rapport au RLHF classique ?

🧩 Quiz — Réponses

1. Comparer deux réponses est **beaucoup plus fiable et cohérent** entre humains que noter une réponse dans l'absolu — un jugement relatif est plus facile à faire qu'un jugement absolu.
2. Elle empêche le modèle de trop s'éloigner de sa version SFT initiale, ce qui évite le **reward hacking** (exploiter des failles du reward model).
3. DPO élimine le besoin d'un **reward model séparé** et d'un algorithme de **RL (PPO)** : l'alignement se fait par une seule perte supervisée, directement sur les paires de préférences.

6. Évaluation

Pourquoi évaluer un LLM est difficile

- Un LLM est **généraliste** : pas de tâche unique à mesurer
- Les benchmarks se **saturent** vite (un nouveau modèle bat le précédent record en quelques mois)
- Risque de **contamination** : le benchmark peut avoir fuité dans les données de pré-entraînement (section 2)
- Un bon score sur un benchmark ne garantit pas une bonne expérience utilisateur réelle

Benchmarks académiques classiques

Benchmark	Mesure	Format
MMLU (Hendrycks et al., 2020)	Connaissances générales, 57 matières	QCM
HellaSwag (Zellers et al., 2019)	Sens commun, complétion de phrase plausible	QCM
GSM8K (Cobbe et al., 2021)	Raisonnement mathématique (niveau collège)	Problèmes ouverts
HumanEval (Chen et al., 2021)	Génération de code fonctionnel	<i>pass@k</i> (le code s'exécute-t-il ?)

Ces benchmarks apparaissent systématiquement dans les *model cards* (GPT-4, Claude, LLaMA, Gemini...) pour comparer les modèles.

Le problème de la contamination

Les modèles sont entraînés sur **une grande partie du web** — qui contient parfois... les benchmarks eux-mêmes, ou leurs solutions.

```
Benchmark public (2019) → indexé sur le web → présent dans Common Crawl (2023)  
    → potentiellement vu pendant le pré-entraînement (2024)  
    → score artificiellement élevé au moment de l'évaluation
```

Conséquence : un score MMLU élevé peut refléter de la **mémorisation** plutôt que de la **généralisation**. D'où l'intérêt de benchmarks récents, privés, ou renouvelés régulièrement.

Évaluation humaine et LLM-as-judge

Face aux limites des QCM, deux approches complémentaires :

Chatbot Arena (LMSYS, 2023) : des humains comparent en aveugle les réponses de deux modèles à un même prompt et votent pour la meilleure → classement de type **Elo** (comme aux échecs).

LLM-as-judge (MT-Bench, Zheng et al., 2023) : on utilise un LLM puissant (GPT-4, Claude) pour **noter automatiquement** les réponses d'autres modèles selon une grille de critères — bien moins cher qu'une évaluation humaine à grande échelle.

⚠ Biais connus du LLM-as-judge : préférence pour les réponses **longues**, pour son **propre style**, sensibilité à l'ordre de présentation.

Quiz — Évaluation

1. Pourquoi un score élevé sur MMLU ne garantit-il pas qu'un modèle est réellement meilleur ?
2. Quelle est la différence entre l'évaluation Chatbot Arena et un benchmark comme HumanEval ?
3. Citez un biais connu du LLM-as-judge.

🧩 Quiz — Réponses

1. Risque de **contamination** : le benchmark (ou ses réponses) peut avoir été vu pendant le pré-entraînement, gonflant artificiellement le score sans réelle généralisation.
2. Chatbot Arena repose sur des **comparaisons humaines en aveugle** avec classement Elo ; HumanEval est un test **automatique et objectif** (le code s'exécute-t-il correctement ?).
3. Préférence pour les réponses longues, préférence pour son propre style de génération, ou sensibilité à l'ordre de présentation des réponses comparées.

Récapitulatif : comment construit-on un LLM ?

```
Texte brut du web (nettoyé)
  ↓ pré-entraînement à grande échelle (loi de Chinchilla : taille ↔ données)
Modèle de base (complète du texte)
  ↓ instruction tuning (SFT)
Modèle qui suit des instructions
  ↓ alignement (RLHF ou DPO)
Assistant aligné sur les préférences humaines
  ↓ évaluation (benchmarks + humains + LLM-as-judge)
Modèle déployé
```


Ressources

- 📄 **Scaling Laws** : Kaplan et al. (2020); arxiv.org/abs/2001.08361
- 📄 **Chinchilla** : Hoffmann et al. (2022); arxiv.org/abs/2203.15556
- 📄 **InstructGPT (RLHF)** : Ouyang et al. (2022); arxiv.org/abs/2203.02155
- 📄 **Self-Instruct** : Wang et al. (2022); arxiv.org/abs/2212.10560
- 📄 **DPO** : Rafailov et al. (2023); arxiv.org/abs/2305.18290
- 📄 **MT-Bench / Chatbot Arena** : Zheng et al. (2023); arxiv.org/abs/2306.05685

- 🔧 **Hugging Face TRL (SFT, DPO, PPO)** : huggingface.co/docs/trl
- 📖 **LMSYS Chatbot Arena** : chat.lmsys.org

Lab : Aujourd'hui (1h-2h)

Partie 1 : Explorer un dataset d'instructions (Alpaca / Dolly)

Observer le format (instruction, réponse), identifier des exemples ambigus ou de mauvaise qualité.

Partie 2 : SFT léger sur un petit modèle avec `TRL` / `transformers`

Fine-tuner un modèle open-source de petite taille sur un sous-ensemble d'instructions.

Partie 3 : Comparer avant / après

Évaluer qualitativement (et via un prompt LLM-as-judge) les réponses du modèle avant et après le SFT.