

# Introduction aux LLMs

Séance 3 : Entraînement LLM

---

4ème année RO DEV - ESGI Paris

Célia Nouri · `celia.nouri@inria.fr`

Semestre 2, 2025–2026

# Agenda

---

1. Tokenization
2. Pré-entraînement à grande échelle
3. Lois de Chinchilla
4. Instruction tuning
5. Alignement : RLHF et DPO

# 1. Tokenization

---

## Rappel : pourquoi tokeniser ?

Les ordinateurs (et les LLMs) ne traitent pas le texte directement → il faut d'abord convertir le texte en une **séquence de vecteurs**.

```
"J'adore le foot"  
  ↓ tokenizer  
["J'", "adore", " le", " foot"] → [4083, 26576, 513, 6821]  
  ↓ embeddings  
[v1, v2, v3, v4] ← vecteurs denses
```

Le tokenizer est donc la **porte d'entrée** du modèle. Son vocabulaire et ses décisions de découpage ont un impact direct sur :

- les performances du modèle
- le coût d'inférence (plus de tokens = plus cher)
- les langues bien ou mal traitées

## Limites de la tokenisation

De nombreux comportements étranges des LLMs — erreurs d'orthographe, de comptage, de calcul — s'expliquent en partie par des choix faits au niveau de la tokenization.

Ce n'est pas un problème résolu, il est donc important de savoir comment les algorithmes de tokenisation fonctionnent.

# Trois stratégies naïves

| Stratégie     | Exemple                              | Problème                                  |
|---------------|--------------------------------------|-------------------------------------------|
| Par mot       | [ "chat", "chats" ] → IDs différents | Mots rares, formes fléchies, OOV          |
| Par caractère | [ "c", "h", "a", "t" ]               | Séquences très longues, peu de sémantique |
| Par sous-mot  | [ "chat", "##s" ]                    | ✅ Bon compromis                           |

Les LLMs modernes utilisent tous une approche **sous-mot** apprise depuis les données.


## Le tokenizer moderne : un objet entraîné

```
"i am loving it!" → ["i", "am", "lov", "##ing", "it", "!" ]
```

- Découpage au niveau **sous-mot** (ni mot entier, ni caractère isolé)
- **Vocabulaire fixe**, appris une fois pour toutes
- **Entraîné** sur un grand échantillon de texte, avant même le pré-entraînement du modèle
- Utilisé ensuite en mode **inférence**, comme étape de **pré-traitement** (jamais ré-entraîné avec le modèle)

Les trois algorithmes principaux pour l'entraîner : **BPE**, **WordPiece**, **Unigram**.

# Granularité



## Granularité : un compromis

→ Compromis entre **séquences courtes** (peu de tokens) et **taille de vocabulaire raisonnable**.

Fertilité — pour un texte  $S$  donné, avec un tokenizer donné :

$$\text{fertilité}(S) = \frac{\# \text{ tokens}}{\# \text{ mots}}$$

La fertilité elle dépend du tokenizer et **texte auquel on l'applique** — même tokenizer, fertilité différente selon la langue ou le domaine.

- À vocabulaire égal, plus une langue est morphologiquement riche et/ou mal représentée à l'entraînement, plus sa fertilité sera élevée
- Fertilité élevée → séquences plus longues → coût d'inférence plus élevé, contexte rempli plus vite

## BPE — Byte-Pair Encoding

Sennrich et al., 2016 — algorithme le plus répandu (GPT, LLaMA, Mistral...).

### Entraînement :

1. Partir du vocabulaire de caractères (ou bytes)
2. Compter toutes les paires adjacentes dans le corpus
3. Fusionner la paire la plus fréquente → nouveau token
4. Répéter jusqu'à atteindre la taille de vocabulaire cible

On obtient une liste ordonnée de **règles de fusion** (*merge rules*), appliquées dans l'ordre à l'inférence.

## BPE — Exemple pas à pas (1/2)

Encodons "aaabdaaabc" :

```
Paires observées : {aa, ab, bd, da, ba, ac}
Occurrences      : {aa: 4, ab: 2, bd: 1, da: 1, ba: 1, ac: 1}
→ règle 1 : aa → X      "aaabdaaabc" devient "XabdXabc"
```

```
Paires observées : {Xa, ab, bd, dX, ba, ac}
Occurrences      : {Xa: 2, ab: 2, bd: 1, dX: 1, ba: 1, ac: 1}
→ règle 2 : ab → Y      "XabdXabc" devient "XYdXYac"
```

On recommence : compter les paires, fusionner la plus fréquente, répéter.

## BPE — Exemple pas à pas (2/2)

```
Paires observées : {XY, Yd, dX, Ya, ac}
Occurrences      : {XY: 2, Yd: 1, dX: 1, Ya: 1, ac: 1}
→ règle 3 : XY → Z      "XYdXYac" devient "ZdZac"

Paires observées : {Zd, dZ, Za, ac} → toutes uniques → FIN
```

**Résultat :** "aaabdaaabc" → "ZdZac", avec les règles de fusion :

1) aa→X    2) ab→Y    3) XY→Z

**Décodage :** appliquer les règles dans l'ordre **inverse**.

## Byte-level BPE

Variante utilisée par **GPT-2, GPT-3, GPT-4, RoBERTa, LLaMA** :

- Vocabulaire de base = **256 bytes** (couvre tout l'Unicode)
- **Jamais de token inconnu** : n'importe quel texte, dans n'importe quelle langue ou encodage, est représentable

**Les fusions se font sur des octets, pas sur des caractères.**

En UTF-8, un caractère peut occuper **plusieurs octets** : "é" = 2 octets ( `0xC3 0xA9` ), un emoji comme "🤖" = 4 octets. Le BPE classique partirait d'un vocabulaire de caractères Unicode (~150 000 possibles) — trop grand, et incomplet.

En partant des **256 octets bruts**, le vocabulaire de départ reste petit et fixe, quelle que soit la langue. L'algorithme apprend ensuite à **fusionner des octets fréquents** — parfois ceux d'un même caractère ( `0xC3 0xA9` → "é" ), parfois ceux de plusieurs caractères qui vont souvent ensemble.

## Byte-level BPE (exemple)

```
# GPT-4 tokenizer (tiktoken)
"ChatGPT" → ["Chat", "G", "PT"]      # mot inconnu → décomposé en bytes connus
"你好"    → ["你", "好"]              # chinois géré nativement
"🤖"      → ["<0xF0>", "<0x9F>", "<0xA4>", "<0x96>"] # emoji → bytes bruts
```

## WordPiece

Algorithme utilisé par **BERT, DistilBERT, ELECTRA**.

**Différence avec BPE** : au lieu de fusionner la paire *la plus fréquente*, on fusionne celle qui **maximise la vraisemblance** du corpus :

$$\text{score}(A, B) = \frac{P(AB)}{P(A) \cdot P(B)}$$

On fusionne  $A$  et  $B$  si les voir ensemble est plus probable que les voir séparément.

**Notation** : les sous-mots de continuation sont préfixés par `##`

```
"playing" → ["play", "##ing"]  
"tokenize" → ["token", "##ize"]
```

## SentencePiece

Bibliothèque de **Kudo & Richardson (2018, Google)**, utilisée pour entraîner et appliquer le tokenizer de **LLaMA** et **Mistral**.

**Innovation clé** : fonctionne directement sur le texte brut, **sans pré-tokenisation par espace**.

```
Word-level tokenizer : "New York" → ["New", "York"]  
SentencePiece       : "New York" → ["_New", "_York"]  
                     (_ = espace encodé comme caractère)
```

### Avantages :

- Universel : pas d'hypothèse sur les espaces (chinois, japonais, thaï...)
- Déterministe et réversible : on peut toujours retrouver le texte original

# Comparatif des tokenizers

| Modèle       | Tokenizer                                  | Taille vocab | Paramètres      |
|--------------|--------------------------------------------|--------------|-----------------|
| GPT-2 (2019) | Byte-level BPE ( gpt2 )                    | 50 257       | 124M – 1,5 Md   |
| GPT-3 (2020) | Byte-level BPE ( p50k_base )               | 50 281       | 125M – 175 Md   |
| GPT-4 (2023) | Byte-level BPE ( cl100k_base )             | ~100 000     | non communiqué* |
| GPT-5 (2025) | Byte-level BPE ( o200k_base ou successeur) | ~200 000     | non communiqué* |
| BERT         | WordPiece                                  | 30 522       | 110M – 340M     |
| LLaMA 1/2    | SentencePiece (BPE)                        | 32 000       | 7 Md – 70 Md    |
| LLaMA 3      | tiktoken (BPE)                             | 128 256      | 8 Md – 405 Md   |
| Mistral      | SentencePiece (BPE)                        | 32 000       | 7 Md            |

## Comparatif des tokenizers

Depuis GPT-4, OpenAI ne publie plus l'architecture ni le nombre de paramètres — seule la taille du vocabulaire est connue (encodages publics via la librairie `tiktoken` ).

Les grands vocabulaires (LLaMA 3, GPT-4/5) améliorent la couverture multilingue et réduisent le nombre de tokens par phrase — la tendance est à la hausse (50k → 200k) au fil des générations.

## Effets pratiques de la tokenization

**Biais multilingue** : pour un même tokenizer, la **fertilité** (tokens/mot, cf. slide "Granularité") varie fortement selon la langue — un token en anglais  $\approx$  1 mot ; en arabe ou en thaï  $\approx$  3–5 tokens pour la même information → coût plus élevé, fenêtre de contexte plus vite remplie.

**Tokens spéciaux** : chaque modèle définit ses propres marqueurs.

```
[BOS] [EOS] [PAD] [UNK]      ← BERT / LLaMA
<endoftext> <im_start>      ← GPT / ChatML
<s> </s> [INST] [/INST]     ← LLaMA 2 chat
```

**Le tokenizer fait partie du modèle** : changer de tokenizer = réentraîner depuis zéro.

## Quiz — Tokenization

1. Quelle est la différence entre BPE et WordPiece ?
2. Pourquoi le *byte-level* BPE ne produit-il jamais de token `[UNK]` ?
3. Un modèle avec un vocabulaire de 128k tokens traite-t-il les textes multilingues mieux ou moins bien qu'un modèle avec 32k tokens ? Pourquoi ?

## 🧩 Quiz — Réponses

1. BPE fusionne la paire *la plus fréquente* ; WordPiece fusionne celle qui maximise la vraisemblance  $P(AB)/(P(A) \cdot P(B))$ .
2. Le vocabulaire de base contient les 256 bytes possibles → tout octet est représentable, donc tout texte est encodable sans token inconnu.
3. **Faux.** SentencePiece encode l'espace comme un caractère `▯`, ce qui lui permet de fonctionner sur du texte brut sans pré-tokenisation.
3. Mieux (en principe) — un grand vocabulaire alloue plus de tokens aux langues non-latines, réduisant le nombre de tokens par phrase et améliorant la représentation. Mais cela dépend du jeu de données d'entraînement du tokenizer.


## 2. Pré-entraînement à grande échelle

---

## La logique des LLMs modernes

**Étape 1 — Pré-entraînement** : tâche non supervisée, immense corpus

**Étape 2 — Fine-tuning / Alignement** : adaptation au comportement souhaité



**Pourquoi cette séparation ?** Le pré-entraînement est coûteux mais ne se fait qu'une fois. Tout le reste (sections 4, 5, 6) part de ce modèle de base.

## Pré-entraînement : prédire le prochain token

Pour un modèle décodeur (type GPT), la tâche est :

Étant donné tous les tokens précédents, prédire le suivant.

```
Input  : "Le chat est assis sur le"  
Cible  : "tapis"
```

- Aucune annotation humaine nécessaire — tout texte est une donnée gratuite
- GPT-3 : ~300 milliards de tokens d'entraînement
- LLaMA 3 : ~15 000 milliards de tokens

## Ce que le modèle apprend implicitement

En apprenant à prédire la suite, le modèle doit **modéliser** :

- La **grammaire** (pour prédire la bonne forme)
- Les **faits du monde** (Paris est la capitale de la France)
- Le **raisonnement** (si A alors B)
- Le **style** et le **ton**
- Les **relations entre concepts**

Les LLMs ne "savent" rien au sens factuel — ils modélisent ce qui est **probable**, pas ce qui est vrai.

# D'où viennent les données ?

| Corpus                           | Contenu                                         | Taille approx.   |
|----------------------------------|-------------------------------------------------|------------------|
| Common Crawl                     | Archive brute du web, depuis 2008               | plusieurs Po     |
| C4 (Google)                      | Common Crawl filtré et nettoyé                  | ~750 Go          |
| The Pile (EleutherAI, 2020)      | 22 sous-corpus : livres, code, PubMed, ArXiv... | 825 Go           |
| FineWeb (Hugging Face, 2024)     | Common Crawl filtré, déduplication poussée      | 15 000 Md tokens |
| Wikipedia, livres, code (GitHub) | Sources denses en connaissance / structure      | variable         |

En pratique, un LLM récent mélange **web généraliste + code + livres + données multilingues**, avec des proportions choisies à la main (*data mixture*).

## Nettoyer les données : pas si simple

Le web brut est plein de **doublons, spam, texte de mauvaise qualité, contenus toxiques**.

### Pipeline typique de nettoyage :

```
Filtrage de langue → Déduplication → Filtrage qualité (heuristiques + classifieur)  
→ Suppression des PII (données personnelles) → Filtrage contenu toxique/NSFW → Mélange des sources
```

### Deux risques concrets :

- **Contamination** : si des benchmarks d'évaluation fuient dans les données d'entraînement, le modèle les "a déjà vus" → scores gonflés (on en parlera plus tard)
- **Droit d'auteur** : procès *New York Times vs OpenAI* (2023) — utiliser des textes protégés pour l'entraînement est-il légal ? Question encore non tranchée juridiquement.

## Quiz — Pré-entraînement

1. Pourquoi le pré-entraînement ne nécessite-t-il aucune annotation humaine ?
2. Citez un risque concret lié à des données d'entraînement mal nettoyées.

## Quiz — Réponses

1. La cible (le token suivant) est déjà présente dans le texte lui-même — tout texte brut fournit ses propres paires (input, cible) gratuitement.
2. Contenus toxiques (racisme, sexisme) appris par le modèle, contamination des benchmarks (scores gonflés artificiellement) ou violation de droits d'auteur (ex. procès NYT vs OpenAI).

### **3. Lois de Chinchilla**

---

## Une question simple, mais coûteuse

Avec un budget de calcul **fixé** (un nombre de GPU pendant un temps donné), faut-il :

- Entraîner un **très grand modèle** sur **peu de données** ?
- Ou un **modèle plus petit** sur **beaucoup plus de données** ?

Se tromper coûte des millions de dollars de calcul gaspillé. Deux papiers y répondent.

## Kaplan et al. (2020) — les premières lois d'échelle

"Scaling Laws for Neural Language Models", OpenAI.

**Constat** : la performance suit une loi de puissance prévisible selon la taille du modèle, la quantité de données et le calcul utilisé.

**Conclusion (de l'époque)** : à budget de calcul fixé, il vaut mieux **prioriser la taille du modèle** et ne pas trop se soucier de la quantité de données.

→ Cette recommandation a motivé des modèles comme **GPT-3 (175B)** ou **Gopher (280B)**.

## Hoffmann et al. (2022) — Chinchilla

"Training Compute-Optimal Large Language Models", DeepMind.

**Résultat surprenant** : la méthodologie de Kaplan et al. sous-estimait l'importance des données. Pour un budget de calcul fixé, **taille du modèle et nombre de tokens doivent croître au même rythme.**

**Règle empirique** : environ **20 tokens d'entraînement par paramètre** pour un usage optimal du calcul.

Conclusion : la plupart des grands modèles de l'époque (dont Gopher) étaient **trop gros et sous-entraînés.**

# La preuve par l'exemple

| Modèle                | Paramètres    | Tokens d'entraînement | Performance             |
|-----------------------|---------------|-----------------------|-------------------------|
| Gopher (DeepMind)     | 280 milliards | 300 milliards         | référence               |
| Chinchilla (DeepMind) | 70 milliards  | 1 400 milliards       | > Gopher, à calcul égal |

Chinchilla est **4× plus petit** que Gopher, entraîné sur **~4.7× plus de tokens**, pour un coût de calcul **identique** — et surpasse Gopher sur la quasi-totalité des benchmarks.

Conséquence directe : de nombreux modèles étaient en réalité **sous-entraînés**, pas trop petits.

## Une nuance importante : le coût d'inférence

Les lois de Chinchilla optimisent le coût de **l'entraînement**. Mais un modèle déployé à grande échelle est **utilisé (inféré) des milliards de fois** après son entraînement.

**LLaMA (Meta, 2023)** a fait un choix différent : entraîner des modèles **plus petits que l'optimum Chinchilla**, mais sur **encore plus de tokens** que ce que Chinchilla recommanderait — pour réduire durablement le coût d'inférence, quitte à dépenser plus de calcul à l'entraînement.

"Compute-optimal" (moins cher à entraîner)  $\neq$  "inference-optimal" (moins cher à faire tourner ensuite).

## Quiz — Chinchilla

1. Quelle est la principale différence entre les conclusions de Kaplan et al. (2020) et Hoffmann et al. (2022) ?
2. LLaMA a choisi d'entraîner des modèles plus petits que l'optimum Chinchilla, mais sur beaucoup plus de tokens que recommandé, quitte à dépenser plus de calcul à l'entraînement. Quel intérêt à long terme justifie ce choix ?

## Quiz — Réponses

1. Kaplan et al. priorisaient la taille du modèle ; Hoffmann et al. montrent que taille du modèle et quantité de données doivent croître **ensemble** (~20 tokens/paramètre).
2. Pour réduire le **coût d'inférence** à long terme : un modèle plus petit et sur-entraîné coûte plus cher à produire mais beaucoup moins cher à faire tourner en production, à qualité égale.

## 4. Instruction tuning

---

## Le problème du modèle brut

Un modèle juste pré-entraîné sait **continuer du texte**, pas **suivre des instructions**.

```
Prompt : "Explique-moi la photosynthèse."
```

```
Modèle pré-entraîné brut :
```

```
"Explique-moi la mitose cellulaire.
```

```
Explique-moi la respiration cellulaire.
```

```
Explique-moi..." ← continue le style d'une liste de questions
```

```
Modèle instruction-tuned :
```

```
"La photosynthèse est le processus par lequel les plantes..."
```

Le modèle de base imite la distribution du **web** — qui contient autant de questions que de réponses.

## Supervised Fine-Tuning (SFT)

**Principe** : ré-entraîner (brièvement) le modèle sur des paires (**instruction, réponse souhaitée**), rédigées ou validées par des humains.

```
Instruction : "Résume ce texte en 3 phrases : [...]"  
Réponse    : "Le texte explique que... En résumé..."
```

- Même fonction de perte que le pré-entraînement (prédiction du prochain token)
- Mais calculée **uniquement sur les tokens de la réponse**, pas sur l'instruction
- Beaucoup moins de données que le pré-entraînement : quelques milliers à quelques millions d'exemples, contre des milliards de documents

## Supervised Fine-Tuning (SFT)

On peut aussi caster des tâches NLP "classiques" (classification de sentiment, de toxicité, NLI, résumé, traduction...) en paires texte → texte, et les mélanger aux instructions.

```
Tâche classique : classifieur("Ce film est nul") → "négatif"
```

```
Reformulée en SFT : Instruction "Ce commentaire est-il positif ou négatif ? [...]" → Réponse "négatif"
```

## D'où viennent ces datasets d'instructions ?

| Dataset                                  | Origine                                                                                   | Idée clé                                         |
|------------------------------------------|-------------------------------------------------------------------------------------------|--------------------------------------------------|
| <b>FLAN</b> (Google, 2021-2022)          | Reformulation de tâches NLP existantes en instructions                                    | Généralisation à des tâches jamais vues          |
| <b>Self-Instruct</b> (Wang et al., 2022) | Un LLM génère <b>lui-même</b> de nouvelles instructions à partir d'exemples de départ     | Réduit le besoin d'annotation humaine            |
| <b>Alpaca</b> (Stanford, 2023)           | 52k instructions générées via Self-Instruct (avec GPT-3), utilisées pour fine-tuner LLaMA | Modèle instruction-tuned pour ~600\$ de coût API |
| <b>Dolly / OpenAssistant</b>             | Instructions rédigées par des humains (employés, volontaires)                             | Données 100% humaines, ouvertes                  |

## Quiz — Instruction tuning

1. Un modèle pré-entraîné brut répond mal à "*Explique-moi la photosynthèse*". Pourquoi ?
2. Sur quels tokens calcule-t-on la perte pendant le SFT : l'instruction, la réponse, ou les deux ?

## Quiz — Réponses

1. Il n'a appris qu'à **continuer du texte** de la même manière que sur le web ; rien ne le pousse à *répondre* plutôt qu'à *continuer la liste de questions*.
2. Uniquement sur les tokens de la **réponse** — l'instruction sert de contexte, pas de cible à prédire.

## 5. Alignement : RLHF et DPO

---

## Pourquoi ne pas s'arrêter au SFT ?

Même après l'instruction tuning, un modèle peut être :

- **Peu utile** : réponses vagues, trop courtes ou trop longues
- **Non sûr** : contenu dangereux, biaisé, ou toxique
- **Mal calibré** sur les préférences humaines fines (ton, style, niveau de détail)

Objectif d'**alignement** (Anthropic, *HHH*) : un modèle **Helpful, Honest, Harmless**.

Le SFT apprend "un exemple correct parmi d'autres". L'alignement apprend **une préférence relative** : "cette réponse est meilleure que celle-là."


## RLHF — Reinforcement Learning from Human Feedback

Ouyang et al. (2022, OpenAI) — pipeline utilisé pour InstructGPT, ancêtre direct de ChatGPT.

```
Étape 1 – SFT           : fine-tuning supervisé (déjà vu)  
Étape 2 – Reward Model  : entraîner un modèle à noter des réponses  
Étape 3 – RL (PPO, proximal policy optimisation) : optimiser le LLM pour maximiser cette note
```

## Étape 1 : Pre-training et SFT

1. Pré-entraînez et finetunez votre modèle sur du texte brut, avec un objectif de CLM (*Causal Language Modeling*, prédiction du prochain token).



## Étape 2 : le modèle de récompense

On ne demande **pas** à des humains de noter une réponse dans l'absolu (trop subjectif) — on leur demande de **comparer** deux réponses.

```
Prompt : "Explique la relativité restreinte."
```

```
Réponse A: [claire, correcte]
```


```
Réponse B: [confuse, un peu fausse]
```

```
Humain : A > B
```

Le **reward model** est entraîné sur des milliers de comparaisons de ce type, pour apprendre à **prédire un score de préférence** pour n'importe quelle réponse.


## Étape 2 : le modèle de récompense

2. Entraînez un second modèle de langage à classer les réponses du premier modèle, en se basant sur des préférences humaines.



## Étape 3 : optimiser avec RL (PPO)

Le LLM est ensuite ajusté pour **générer des réponses que le reward model note bien** — via l'algorithme PPO (Proximal Policy Optimization).



## Étape 3 : optimiser avec RL (PPO)

LLM génère une réponse → Reward Model la note → PPO ajuste les poids du LLM pour augmenter la note future

**Garde-fou essentiel** : une pénalité **KL-divergence** empêche le modèle de trop s'éloigner du modèle SFT initial — sinon il apprend à "tricher" avec le reward model (*reward hacking*) au lieu de vraiment s'améliorer.

## Les limites du RLHF

- **Pipeline complexe** : 3 modèles à entraîner et maintenir (SFT, reward model, politique RL)
- **RL instable** : sensible aux hyperparamètres, coûteux à faire converger
- **Reward hacking** : le modèle peut exploiter des failles du reward model plutôt que réellement s'améliorer
- Nécessite de **stocker et faire tourner** le reward model en plus du LLM pendant l'entraînement

→ Motive une simplification : peut-on aligner un modèle **sans** RL ni reward model séparé ?

## DPO — Direct Preference Optimization


Rafailov et al. (2023) — *"Direct Preference Optimization: Your Language Model is Secretly a Reward Model"*

**Idée clé** : on peut montrer mathématiquement qu'un objectif RLHF (reward model + PPO) admet une solution optimale exprimable **directement** en fonction du modèle de langage lui-même.

**Résultat** : **pas besoin d'entraîner un reward model séparé, ni de faire du RL**. On optimise directement une perte de classification sur les paires (réponse préférée, réponse rejetée).

```
DPO : ajuster le LLM pour augmenter P(réponse préférée)
      et diminuer P(réponse rejetée) — directement, par descente de gradient
```

# RLHF vs DPO



# RLHF vs DPO

| Modèles à entraîner | SFT + Reward Model + Policy RL    | SFT + un seul modèle final                              |
|---------------------|-----------------------------------|---------------------------------------------------------|
| Algorithme          | PPO (reinforcement learning)      | Descente de gradient supervisée                         |
| Stabilité           | Sensible, coûteux à régler        | Plus simple, plus stable                                |
| Popularité (2023+)  | Standard historique (InstructGPT) | Largement adopté (Zephyr, Mixtral-Instruct, LLaMA 3...) |

DPO ne remplace pas la **collecte de préférences humaines** — seulement la façon d'optimiser le modèle à partir de ces préférences.

## Quiz — RLHF & DPO

1. Pourquoi demande-t-on aux humains de **comparer** deux réponses plutôt que de noter une réponse seule ?
2. À quoi sert la pénalité KL-divergence pendant l'étape RL du RLHF ?
3. Quelle est la principale simplification qu'apporte DPO par rapport au RLHF classique ?

## 🧩 Quiz — Réponses

1. Comparer deux réponses est **beaucoup plus fiable et cohérent** entre humains que noter une réponse dans l'absolu — un jugement relatif est plus facile à faire qu'un jugement absolu.
2. Elle empêche le modèle de trop s'éloigner de sa version SFT initiale, ce qui évite le **reward hacking** (exploiter des failles du reward model).
3. DPO élimine le besoin d'un **reward model séparé** et d'un algorithme de **RL (PPO)** : l'alignement se fait par une seule perte supervisée, directement sur les paires de préférences.

## Récapitulatif : comment construit-on un LLM ?

```
Texte brut du web (nettoyé)
  ↓ pré-entraînement à grande échelle (loi de Chinchilla : taille ↔ données)
Modèle de base (complète du texte)
  ↓ instruction tuning (SFT)
Modèle qui suit des instructions
  ↓ alignement (RLHF ou DPO)
Assistant aligné sur les préférences humaines
  ↓ évaluation (benchmarks + humains + LLM-as-judge)
Modèle déployé
```

## Ressources

- 📄 **Scaling Laws** : Kaplan et al. (2020); [arxiv.org/abs/2001.08361](https://arxiv.org/abs/2001.08361)
  - 📄 **Chinchilla** : Hoffmann et al. (2022); [arxiv.org/abs/2203.15556](https://arxiv.org/abs/2203.15556)
  - 📄 **InstructGPT (RLHF)** : Ouyang et al. (2022); [arxiv.org/abs/2203.02155](https://arxiv.org/abs/2203.02155)
  - 📄 **Self-Instruct** : Wang et al. (2022); [arxiv.org/abs/2212.10560](https://arxiv.org/abs/2212.10560)
  - 📄 **DPO** : Rafailov et al. (2023); [arxiv.org/abs/2305.18290](https://arxiv.org/abs/2305.18290)
- 
- 🔧 **Hugging Face TRL** (SFT, DPO, PPO) : [huggingface.co/docs/trl](https://huggingface.co/docs/trl)

## Lab : Aujourd'hui (1h-2h)

### Partie 1 : Explorer un dataset d'instructions (Alpaca / Dolly)

Observer le format (instruction, réponse), identifier des exemples ambigus ou de mauvaise qualité.

### Partie 2 : SFT léger sur un petit modèle avec `TRL` / `transformers`

Fine-tuner un modèle open-source de petite taille sur un sous-ensemble d'instructions.

### Partie 3 : Comparer avant / après

Évaluer qualitativement (et via un prompt LLM-as-judge) les réponses du modèle avant et après le SFT.