

Introduction aux LLMs

Séance 3 : Entraînement LLM

ESGI Paris

Célia Nouri · `celia.nouri@inria.fr`

Semestre 1, 2026–2027

Agenda


1. Pré-entraînement à grande échelle
2. Lois de Chinchilla
3. Instruction tuning
4. Alignement : RLHF et DPO

1. Pré-entraînement à grande échelle

La logique des LLMs modernes

Étape 1 — Pré-entraînement : tâche non supervisée, immense corpus

Étape 2 — Fine-tuning / Alignement : adaptation au comportement souhaité



Pourquoi cette séparation ? Le pré-entraînement est coûteux mais ne se fait qu'une fois. Tout le reste (sections 4, 5, 6) part de ce modèle de base.

Pré-entraînement : prédire le prochain token

Pour un modèle décodeur (type GPT), la tâche est :

- **Étant donné tous les tokens précédents, prédire le suivant.**

Input : "Le chat est assis sur le"

Cible : "tapis"

- Aucune annotation humaine nécessaire — tout texte est une donnée gratuite
- GPT-3 : ~300 milliards de tokens d'entraînement
- LLaMA 3 : ~15 000 milliards de tokens

Ce que le modèle apprend implicitement

En apprenant à prédire la suite, le modèle doit **modéliser** :

- La **grammaire** (pour prédire la bonne forme)
- Les **faits du monde** (Paris est la capitale de la France)
- Le **raisonnement** (si A alors B)
- Le **style** et le **ton**
- Les **relations entre concepts**

Les LLMs ne "savent" rien au sens factuel — ils modélisent ce qui est **probable**, pas ce qui est vrai.

D'où viennent les données ?

Corpus	Contenu	Taille approx.
Common Crawl	Archive brute du web, depuis 2008	plusieurs Po
C4 (Google)	Common Crawl filtré et nettoyé	~750 Go
The Pile (EleutherAI, 2020)	22 sous-corpus : livres, code, PubMed, ArXiv...	825 Go
FineWeb (Hugging Face, 2024)	Common Crawl filtré, déduplication poussée	15 000 Md tokens
Wikipedia, livres, code (GitHub)	Sources denses en connaissance / structure	variable

En pratique, un LLM récent mélange **web généraliste + code + livres + données multilingues**, avec des proportions choisies à la main (*data mixture*).

Nettoyer les données : pas si simple

Le web brut est plein de **doublons, spam, texte de mauvaise qualité, contenus toxiques**.

Pipeline typique de nettoyage :

Filtrage de langue → Déduplication → Filtrage qualité (heuristiques + classifieur)
→ Suppression des PII (données personnelles) → Filtrage contenu toxique/NSFW → Mélange des sources

Deux risques concrets :

- **Contamination** : si des benchmarks d'évaluation fuient dans les données d'entraînement, le modèle les "a déjà vus" → scores gonflés (on en parlera plus tard)
- **Droit d'auteur** : procès *New York Times vs OpenAI* (2023) — utiliser des textes protégés pour l'entraînement est-il légal ? Question encore non tranchée juridiquement.

Quiz — Pré-entraînement

1. Pourquoi le pré-entraînement ne nécessite-t-il aucune annotation humaine ?
2. Citez un risque concret lié à des données d'entraînement mal nettoyées.

Quiz — Réponses

- 1.** La cible (le token suivant) est déjà présente dans le texte lui-même — tout texte brut fournit ses propres paires (input, cible) gratuitement.
- 2.** Contenus toxiques (racisme, sexisme) appris par le modèle, contamination des benchmarks (scores gonflés artificiellement) ou violation de droits d'auteur (ex. procès NYT vs OpenAI).

2. Lois de Chinchilla

Une question simple, mais coûteuse

Avec un budget de calcul **fixé** (un nombre de GPU pendant un temps donné), faut-il :

- Entraîner un **très grand modèle** sur **peu de données** ?
- Ou un **modèle plus petit** sur **beaucoup plus de données** ?

Se tromper coûte des millions de dollars de calcul gaspillé.

Loi de Chinchilla

"Training Compute-Optimal Large Language Models", DeepMind.

Constat : la performance suit une loi de puissance prévisible selon la taille du modèle, la quantité de données et le calcul utilisé.

Pour un budget de calcul fixé, **taille du modèle et nombre de tokens doivent croître au même rythme**. La plupart des grands modèles de l'époque (dont Gopher) étaient **trop gros et sous-entraînés**.

Règle empirique : environ **20 tokens d'entraînement par paramètre** pour un usage optimal du calcul.

Une nuance importante : le coût d'inférence

Les lois de Chinchilla optimisent le coût de **l'entraînement**. Mais un modèle déployé à grande échelle est **utilisé (inféré) des milliards de fois** après son entraînement.

LLaMA (Meta, 2023) a fait un choix différent : entraîner des modèles **plus petits que l'optimum Chinchilla**, mais sur **encore plus de tokens** que ce que Chinchilla recommanderait — pour réduire durablement le coût d'inférence, quitte à dépenser plus de calcul à l'entraînement.

- "Compute-optimal" (moins cher à entraîner) $\neq$ "inference-optimal" (moins cher à faire tourner ensuite).

3. Instruction tuning

Le problème du modèle brut

Un modèle juste pré-entraîné sait **continuer du texte**, pas **suivre des instructions**.

Prompt : "Explique-moi la photosynthèse."

Modèle pré-entraîné brut :

"Explique-moi la mitose cellulaire.

Explique-moi la respiration cellulaire.

Explique-moi..." ← continue le style d'une liste de questions

Modèle instruction-tuned :

"La photosynthèse est le processus par lequel les plantes..."

Le modèle de base imite la distribution du **web** — qui contient autant de questions que de réponses.

Supervised Fine-Tuning (SFT)

Principe : ré-entraîner (brièvement) le modèle sur des paires **(instruction, réponse souhaitée)**, rédigées ou validées par des humains.

```
Instruction : "Résume ce texte en 3 phrases : [...]"  
Réponse    : "Le texte explique que... En résumé..."
```

- Même fonction de perte que le pré-entraînement (prédiction du prochain token)
- Mais calculée **uniquement sur les tokens de la réponse**, pas sur l'instruction
- Beaucoup moins de données que le pré-entraînement : quelques milliers à quelques millions d'exemples, contre des milliards de documents

Supervised Fine-Tuning (SFT)

On peut aussi caster des tâches NLP "classiques" (classification de sentiment, de toxicité, NLI, résumé, traduction...) en paires texte → texte, et les mélanger aux instructions.

Tâche classique : classifieur("Ce film est nul") → "négatif"

Reformulée en SFT : Instruction "Ce commentaire est-il positif ou négatif ? [...]" → Réponse "négatif"

D'où viennent ces datasets d'instructions ?

Dataset	Origine	Idée clé
FLAN (Google, 2021-2022)	Reformulation de tâches NLP existantes en instructions	Généralisation à des tâches jamais vues
Self-Instruct (Wang et al., 2022)	Un LLM génère lui-même de nouvelles instructions à partir d'exemples de départ	Réduit le besoin d'annotation humaine
Alpaca (Stanford, 2023)	52k instructions générées via Self-Instruct (avec GPT-3), utilisées pour fine-tuner LLaMA	Modèle instruction-tuned pour ~600\$ de coût API
Dolly / OpenAssistant	Instructions rédigées par des humains (employés, volontaires)	Données 100% humaines, ouvertes

Quiz — Instruction tuning

1. Un modèle pré-entraîné brut répond mal à *"Explique-moi la photosynthèse"*. Pourquoi ?
2. Sur quels tokens calcule-t-on la perte pendant le SFT : l'instruction, la réponse, ou les deux ?

Quiz — Réponses

1. Il n'a appris qu'à **continuer du texte** de la même manière que sur le web ; rien ne le pousse à *répondre* plutôt qu'à *continuer la liste de questions*.
2. Uniquement sur les tokens de la **réponse** — l'instruction sert de contexte, pas de cible à prédire.

4. Alignement : RLHF et DPO

Pourquoi ne pas s'arrêter au SFT ?

Même après l'instruction tuning, un modèle peut être :

- **Peu utile** : réponses vagues, trop courtes ou trop longues
- **Non sûr** : contenu dangereux, biaisé, ou toxique
- **Mal calibré** sur les préférences humaines fines (ton, style, niveau de détail)

Objectif d'**alignement** (Anthropic, *HHH*) : un modèle **Helpful, Honest, Harmless**.

- Le SFT apprend "un exemple correct parmi d'autres". L'alignement apprend **une préférence relative** : "cette réponse est meilleure que celle-là."


RLHF — Reinforcement Learning from Human Feedback

Ouyang et al. (2022, OpenAI) — pipeline utilisé pour **InstructGPT**, ancêtre direct de ChatGPT.

Étape 1 – SFT : fine-tuning supervisé (déjà vu)
Étape 2 – Reward Model : entraîner un modèle à noter des réponses
Étape 3 – RL (PPO, proximal policy optimisation) : optimiser le LLM pour maximiser cette note

Étape 1 : Pre-training et SFT

1. Pré-entraînez et finetunez votre modèle sur du texte brut, avec un objectif de CLM (*Causal Language Modeling*, prédiction du prochain token).



Étape 2 : le modèle de récompense


On ne demande **pas** à des humains de noter une réponse dans l'absolu (trop subjectif) — on leur demande de **comparer** deux réponses.

```
Prompt    : "Explique la relativité restreinte."  
Réponse A: [claire, correcte]  
Réponse B: [confuse]  
  
Humain    : A > B
```

Le **reward model** est entraîné sur des milliers de comparaisons de ce type, pour apprendre à **prédire un score de préférence** pour n'importe quelle réponse.


Étape 2 : le modèle de récompense

2. Entraînez un second modèle de langage à classer les réponses du premier modèle, en se basant sur des préférences humaines.



Étape 3 : optimiser avec RL (PPO)

Le LLM est ensuite ajusté pour **générer des réponses que le reward model note bien** — via l'algorithme **PPO** (Proximal Policy Optimization).



Étape 3 : optimiser avec RL (PPO)

LLM génère une réponse → Reward Model la note → PPO ajuste les poids du LLM pour augmenter la note future

Garde-fou essentiel : une pénalité **KL-divergence** empêche le modèle de trop s'éloigner du modèle SFT initial — sinon il apprend à "tricher" avec le reward model (*reward hacking*) au lieu de vraiment s'améliorer.

Les limites du RLHF

- **Pipeline complexe** : 3 modèles à entraîner et maintenir (SFT, reward model, politique RL)
- **RL instable** : sensible aux hyperparamètres, coûteux à faire converger
- **Reward hacking** : le modèle peut exploiter des failles du reward model plutôt que réellement s'améliorer
- Nécessite de **stocker et faire tourner** le reward model en plus du LLM pendant l'entraînement

→ Motive une simplification : peut-on aligner un modèle **sans** RL ni reward model séparé ?

DPO — Direct Preference Optimization



Rafailov et al. (2023) — *"Direct Preference Optimization: Your Language Model is Secretly a Reward Model"*

Idée clé : on peut montrer mathématiquement qu'un objectif RLHF (reward model + PPO) admet une solution optimale exprimable **directement** en fonction du modèle de langage lui-même.

Résultat : **pas besoin d'entraîner un reward model séparé, ni de faire du RL**. On optimise directement une perte de classification sur les paires (réponse préférée, réponse rejetée).

DPO : ajuster le LLM pour augmenter $P(\text{réponse préférée})$
et diminuer $P(\text{réponse rejetée})$ — directement, par descente de gradient

RLHF vs DPO



RLHF vs DPO

	RLHF	DPO
Modèles à entraîner	SFT + Reward Model + Policy RL	SFT + un seul modèle final
Algorithme	PPO (reinforcement learning)	Descente de gradient supervisée
Stabilité	Sensible, coûteux à régler	Plus simple, plus stable
Popularité (2023+)	Standard historique (InstructGPT)	Largement adopté (Zephyr, Mixtral-Instruct, LLaMA 3...)

DPO ne remplace pas la **collecte de préférences humaines** — seulement la façon d'optimiser le modèle à partir de ces préférences.

Quiz — RLHF & DPO

1. Pourquoi demande-t-on aux humains de **comparer** deux réponses plutôt que de noter une réponse seule ?
2. À quoi sert la pénalité KL-divergence pendant l'étape RL du RLHF ?
3. Quelle est la principale simplification qu'apporte DPO par rapport au RLHF classique ?

Quiz — Réponses

1. Comparer deux réponses est **beaucoup plus fiable et cohérent** entre humains que noter une réponse dans l'absolu — un jugement relatif est plus facile à faire qu'un jugement absolu.
2. Elle empêche le modèle de trop s'éloigner de sa version SFT initiale, ce qui évite le **reward hacking** (exploiter des failles du reward model).
3. DPO élimine le besoin d'un **reward model séparé** et d'un algorithme de **RL (PPO)** : l'alignement se fait par une seule perte supervisée, directement sur les paires de préférences.

Récapitulatif : comment construit-on un LLM ?

Texte brut du web (nettoyé)

↓ pré-entraînement à grande échelle (loi de Chinchilla : taille ↔ données)

Modèle de base (complète du texte)

↓ instruction tuning (SFT)

Modèle qui suit des instructions

↓ alignement (RLHF ou DP0)

Assistant aligné sur les préférences humaines

↓ évaluation (benchmarks + humains + LLM-as-judge)

Modèle déployé

Ressources

-  **Scaling Laws** : Kaplan et al. (2020); arxiv.org/abs/2001.08361
-  **Chinchilla** : Hoffmann et al. (2022); arxiv.org/abs/2203.15556
-  **InstructGPT (RLHF)** : Ouyang et al. (2022); arxiv.org/abs/2203.02155
-  **Self-Instruct** : Wang et al. (2022); arxiv.org/abs/2212.10560
-  **DPO** : Rafailov et al. (2023); arxiv.org/abs/2305.18290

 **Hugging Face TRL** (SFT, DPO, PPO) : huggingface.co/docs/trl

Lab : Aujourd'hui (1h-2h)

Partie 1 : Explorer un dataset d'instructions (Alpaca / Dolly)

Observer le format (instruction, réponse), identifier des exemples ambigus ou de mauvaise qualité.

Partie 2 : SFT léger sur un petit modèle avec `TRL` / `transformers`